网易云 Kubernetes 性能优化实践

赖冬林，2017-12-22

不用很累很麻烦的性能优化实践

赖冬林， 2017-12-22

为什么要优化 Kubernetes?

为什么要优化 Kubernetes？

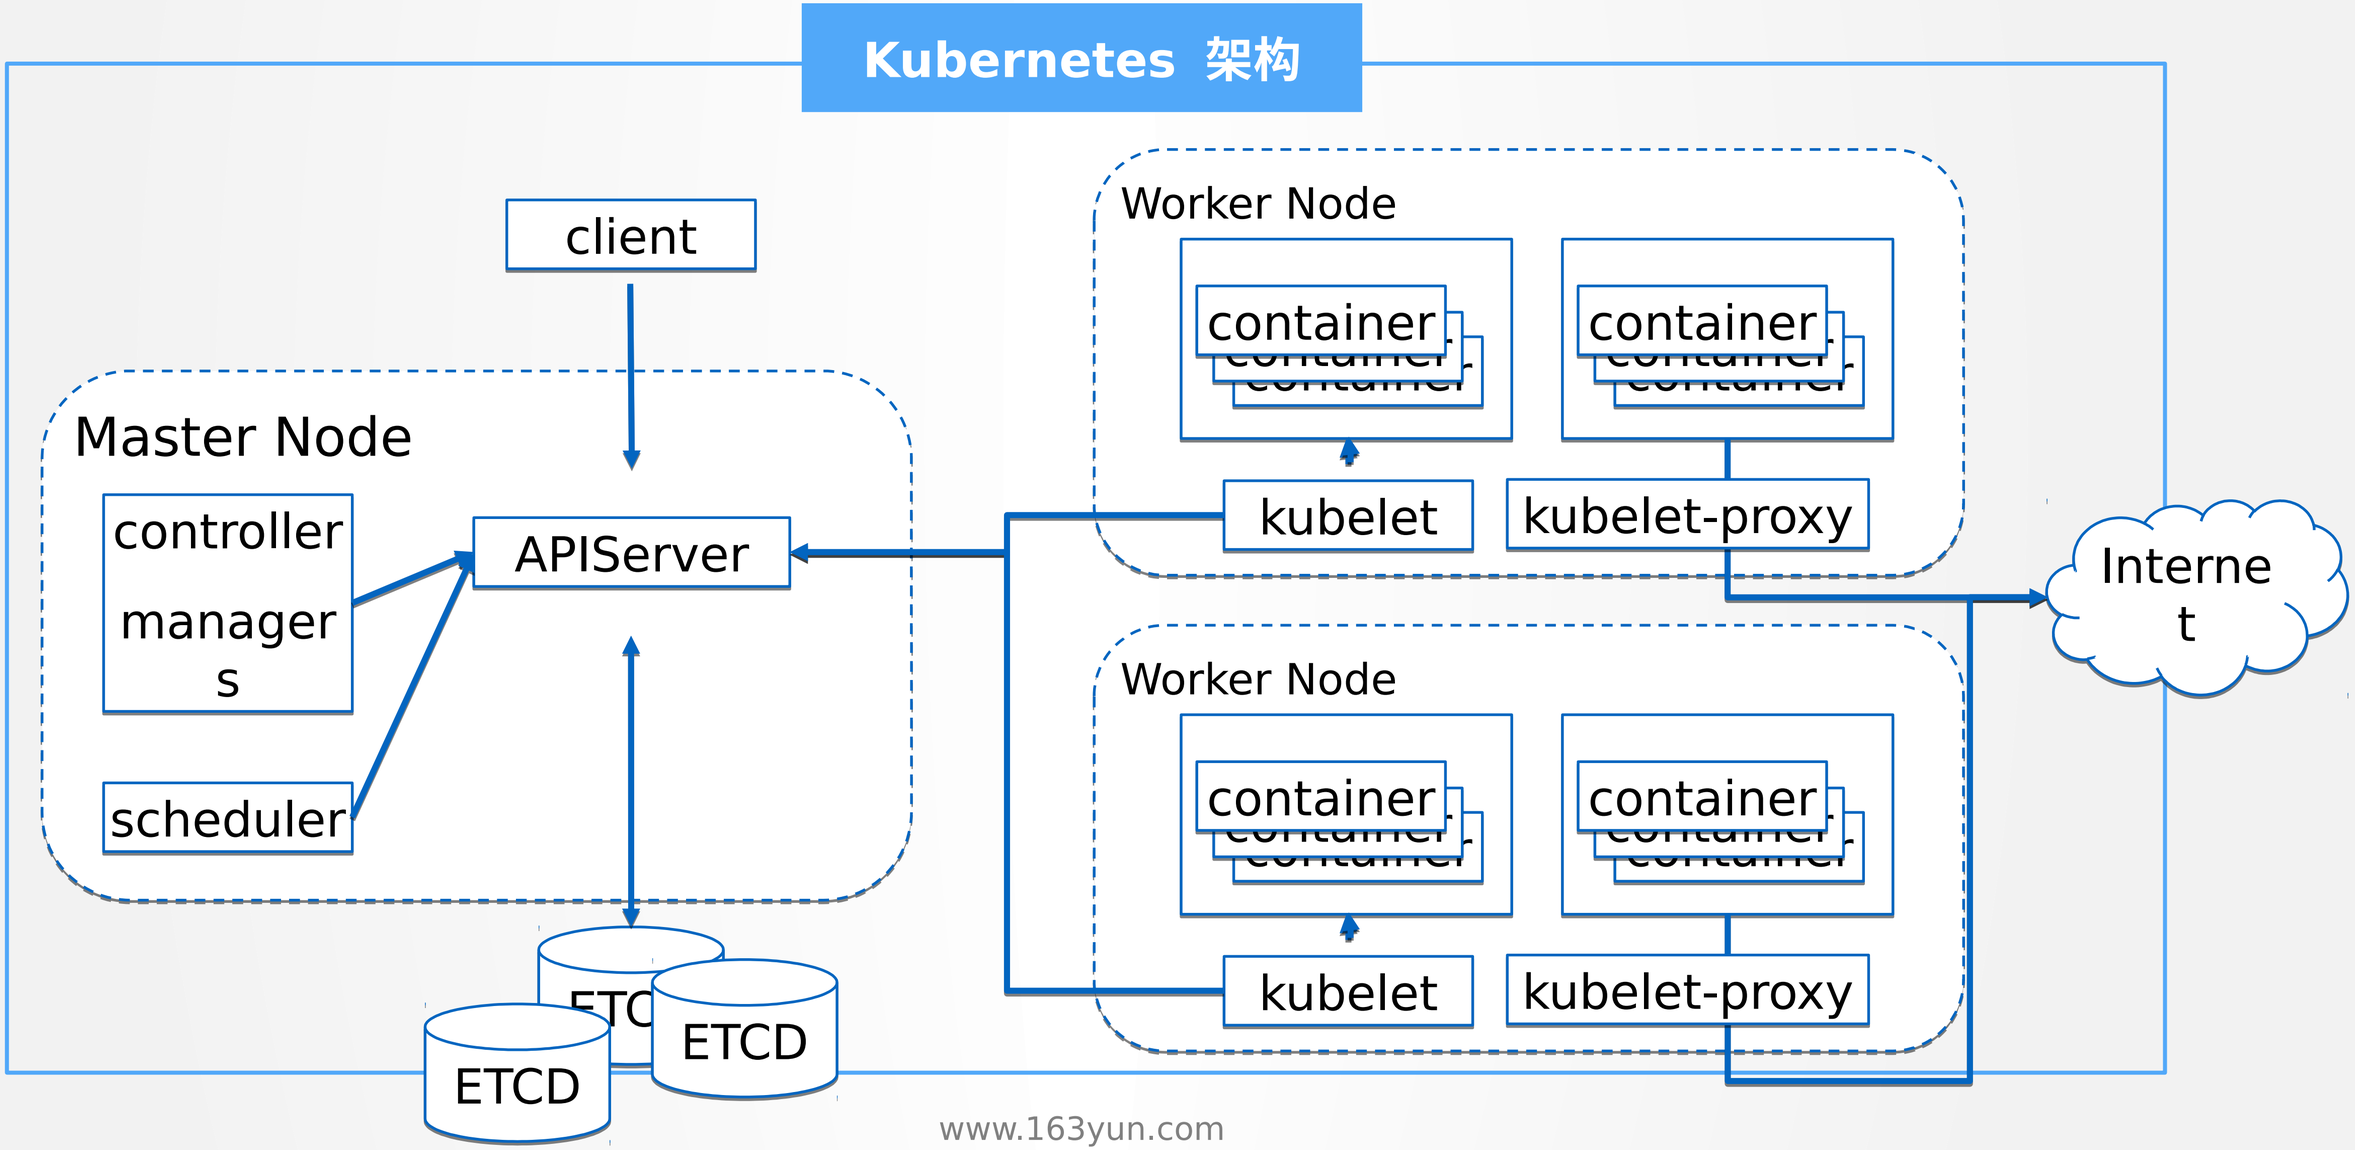

为什么要优化 Kubernetes？

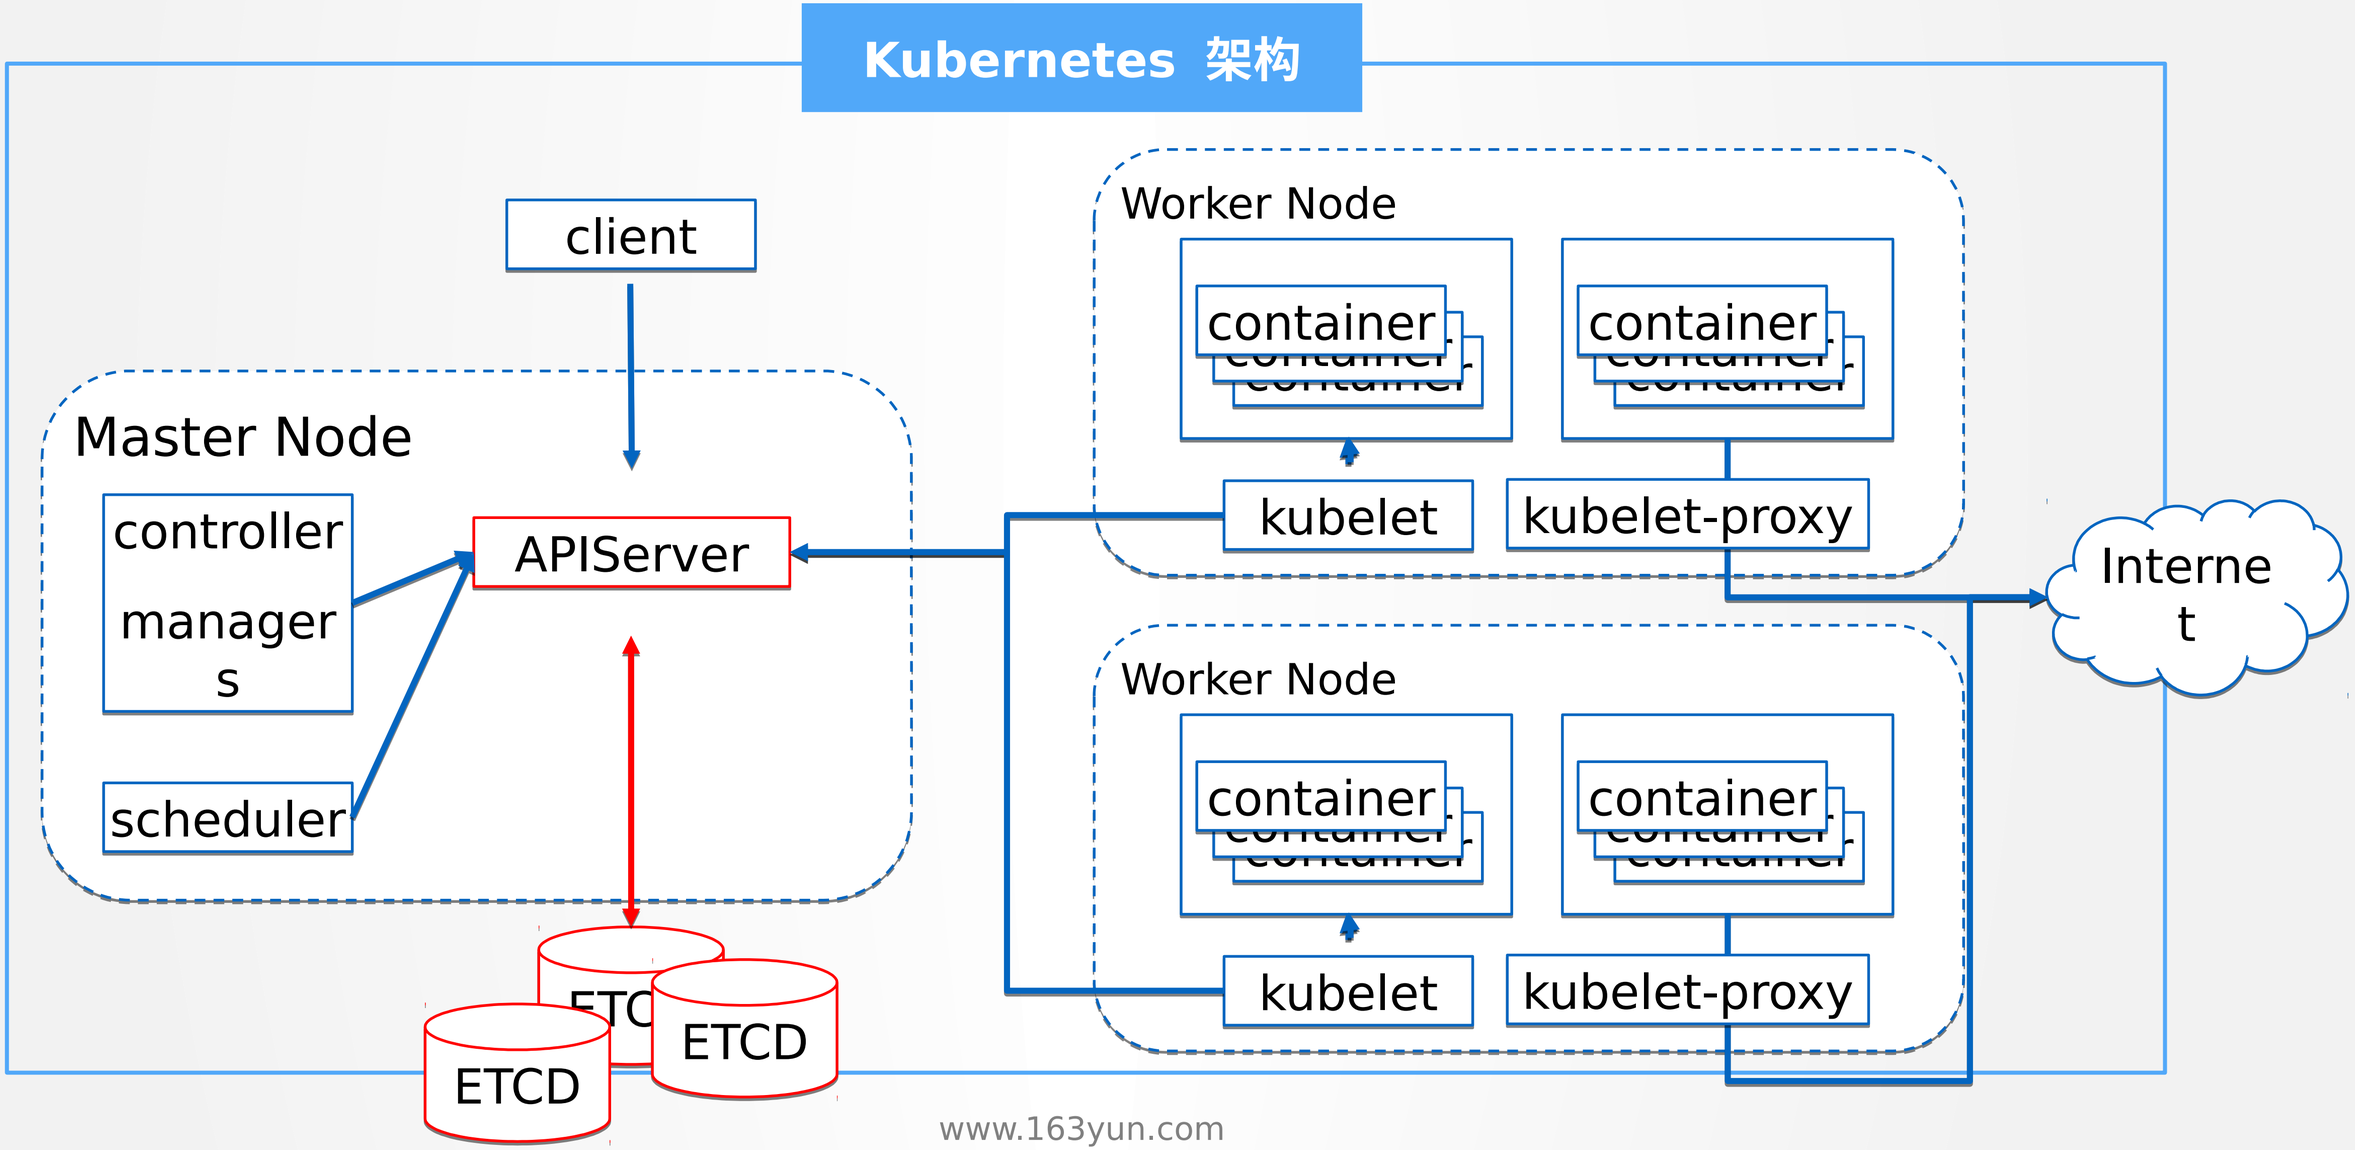

为什么要优化 Kubernetes？

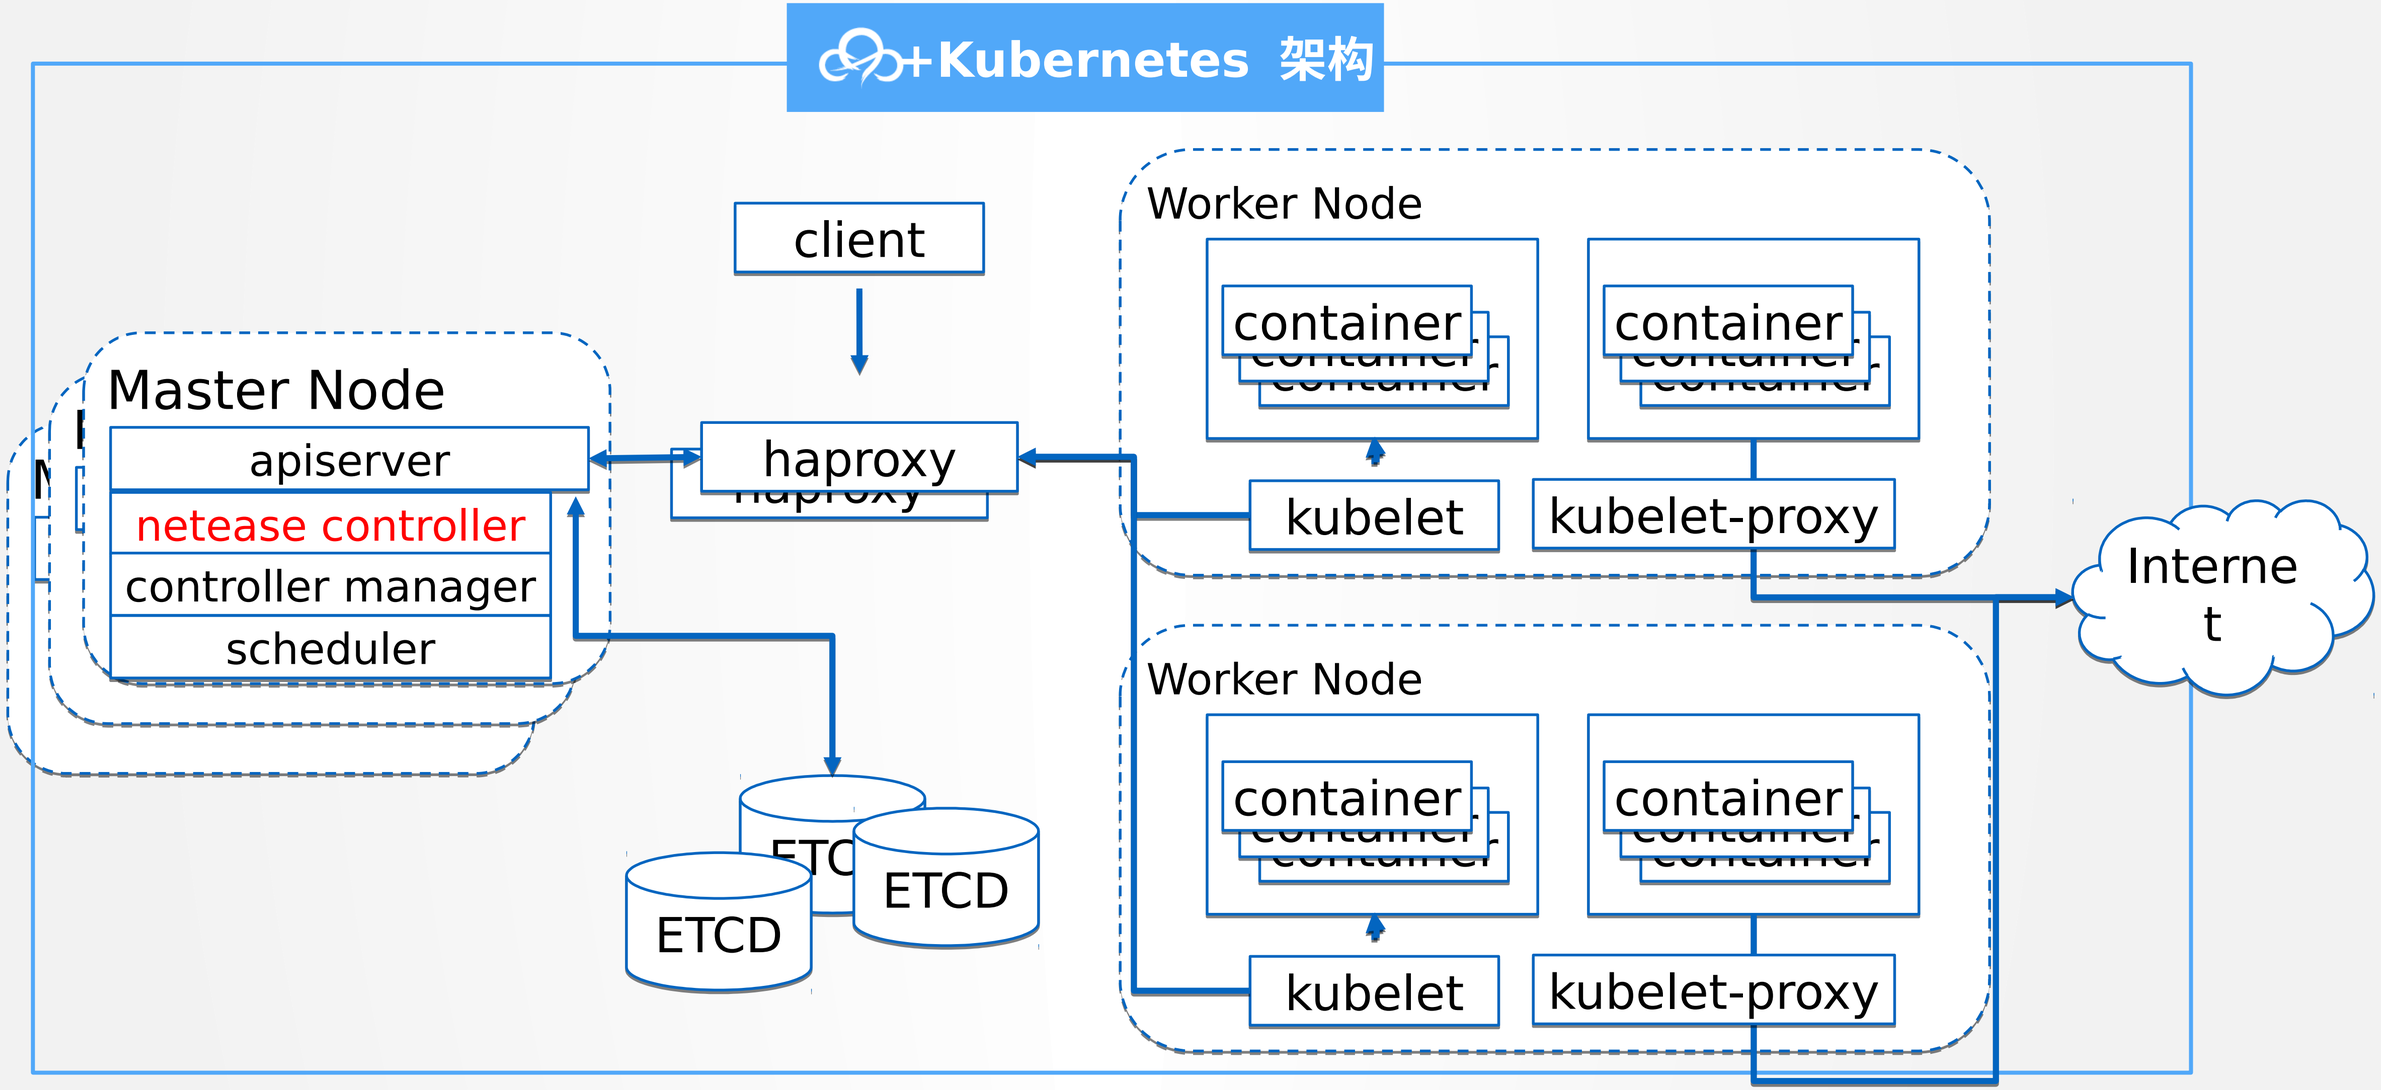

为什么要优化 Kubernetes？

网易云

业务压力

- 服务于网易互联网产品
- 云音乐
- 考拉
- 网易新闻
- 云阅读
- 云课堂
- ……

产品需求

- 面向公有云
- 多租户
- 专属云
- ……

最重要的是：节省成本！为老板省钱！

为什么要优化 Kubernetes？

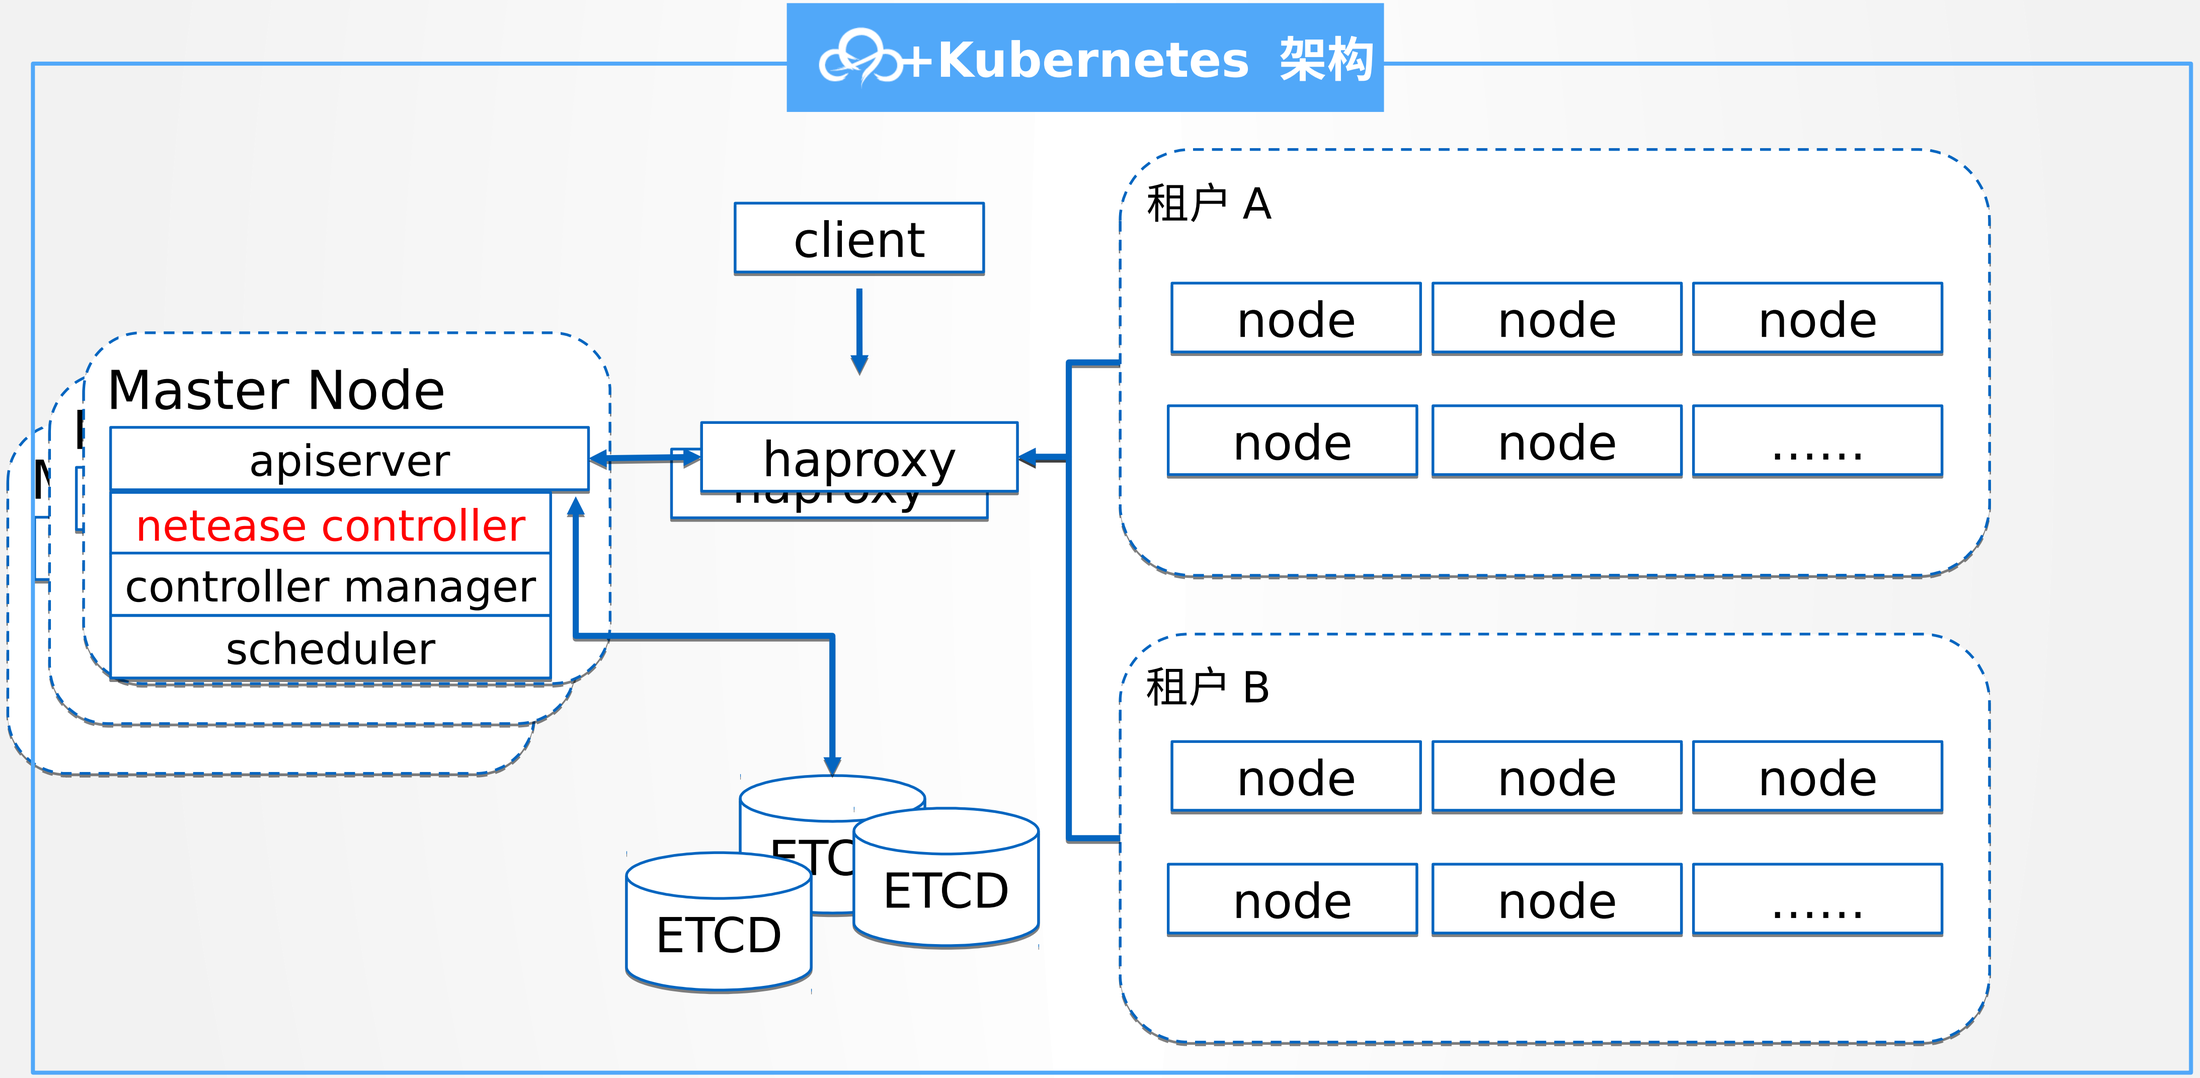

为什么要优化 Kubernetes？

原生版本性能

- 1.0 – 100 Node / 3000 Pod
- 1.3 – 2000 Node / 60k Pod
- 1.6 – 5000 Node / 150k Pod

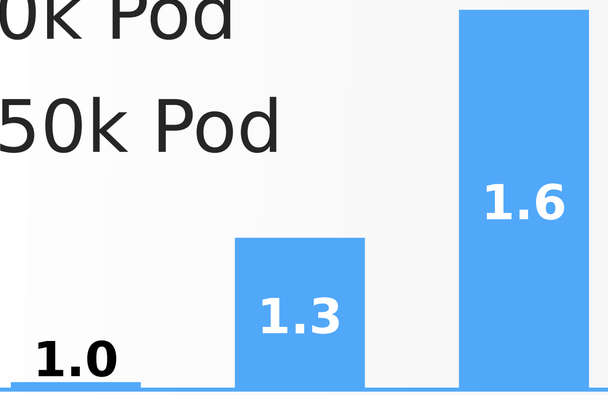

为什么要优化 Kubernetes？

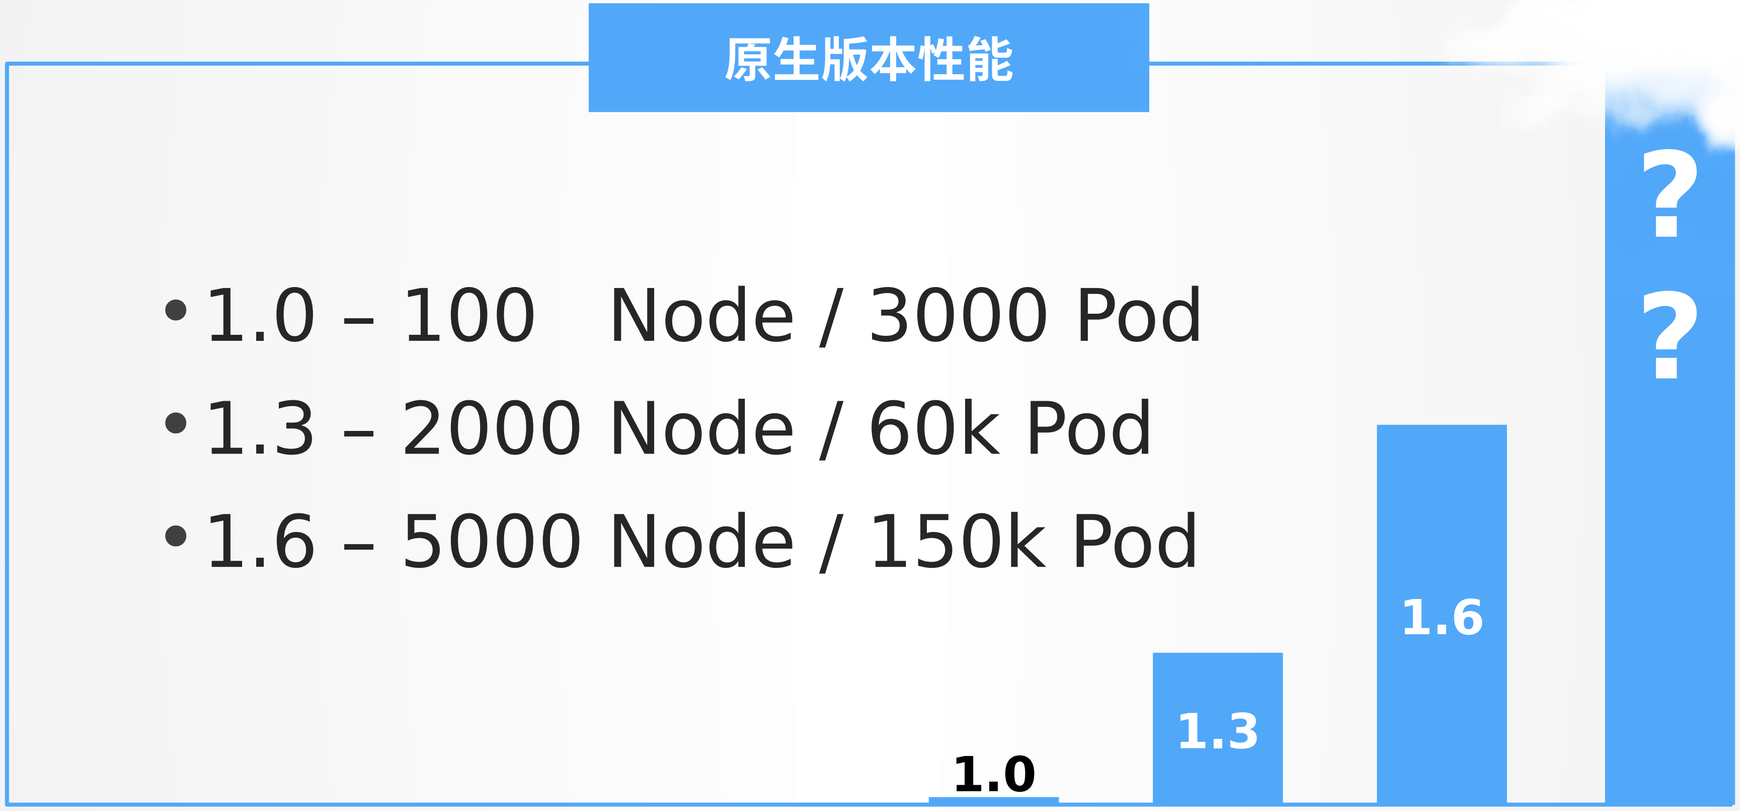

都远达不到我们的目标是： 单集群 30k Node

为什么要优化 Kubernetes？

网易云

环境与性能标准

- Master 机器：物理机 E5-2650v3 X 2/256G RAM/10G NIC/SSD

- 通过标准
- 排除 WATCH，所有 API 响应时间的 99 值最大为 100ms
- pod 创建成功和 container 成功运行耗时的 99 值在 5s 内
- deployment 创建时间耗时的 99 值在 15s 内
- 所有 P0 场景错误率 0%
- apiserver 进程的 cpu 使用率少于 70%（针对 40 核机器而言，<2800%）
- 运维操作恢复时间： Master<3min，批量 kubelet 运维 < 10min

如何优化 Kubernetes?

如何优化 Kubernetes？

网易云

基本原则

- 方法论 USE
- 指标收集
- 性能剖析
- 优化措施

如何优化 Kubernetes？

方法论 USE

- Utility： CPU/ 内存 / 磁盘 / 网络利用率
- Saturation： 各种队列长度 / 饱和度
- Error： 协议栈错误、应用层错误日志

By Bredan Gregg

http://www.brendangregg.com/usemethod.html

如何优化 Kubernetes？

网易云

指标收集

- 系统指标：　top/sysstat 包等 (debian)
- 应用指标：　prometheus + grafana

如何优化 Kubernetes？

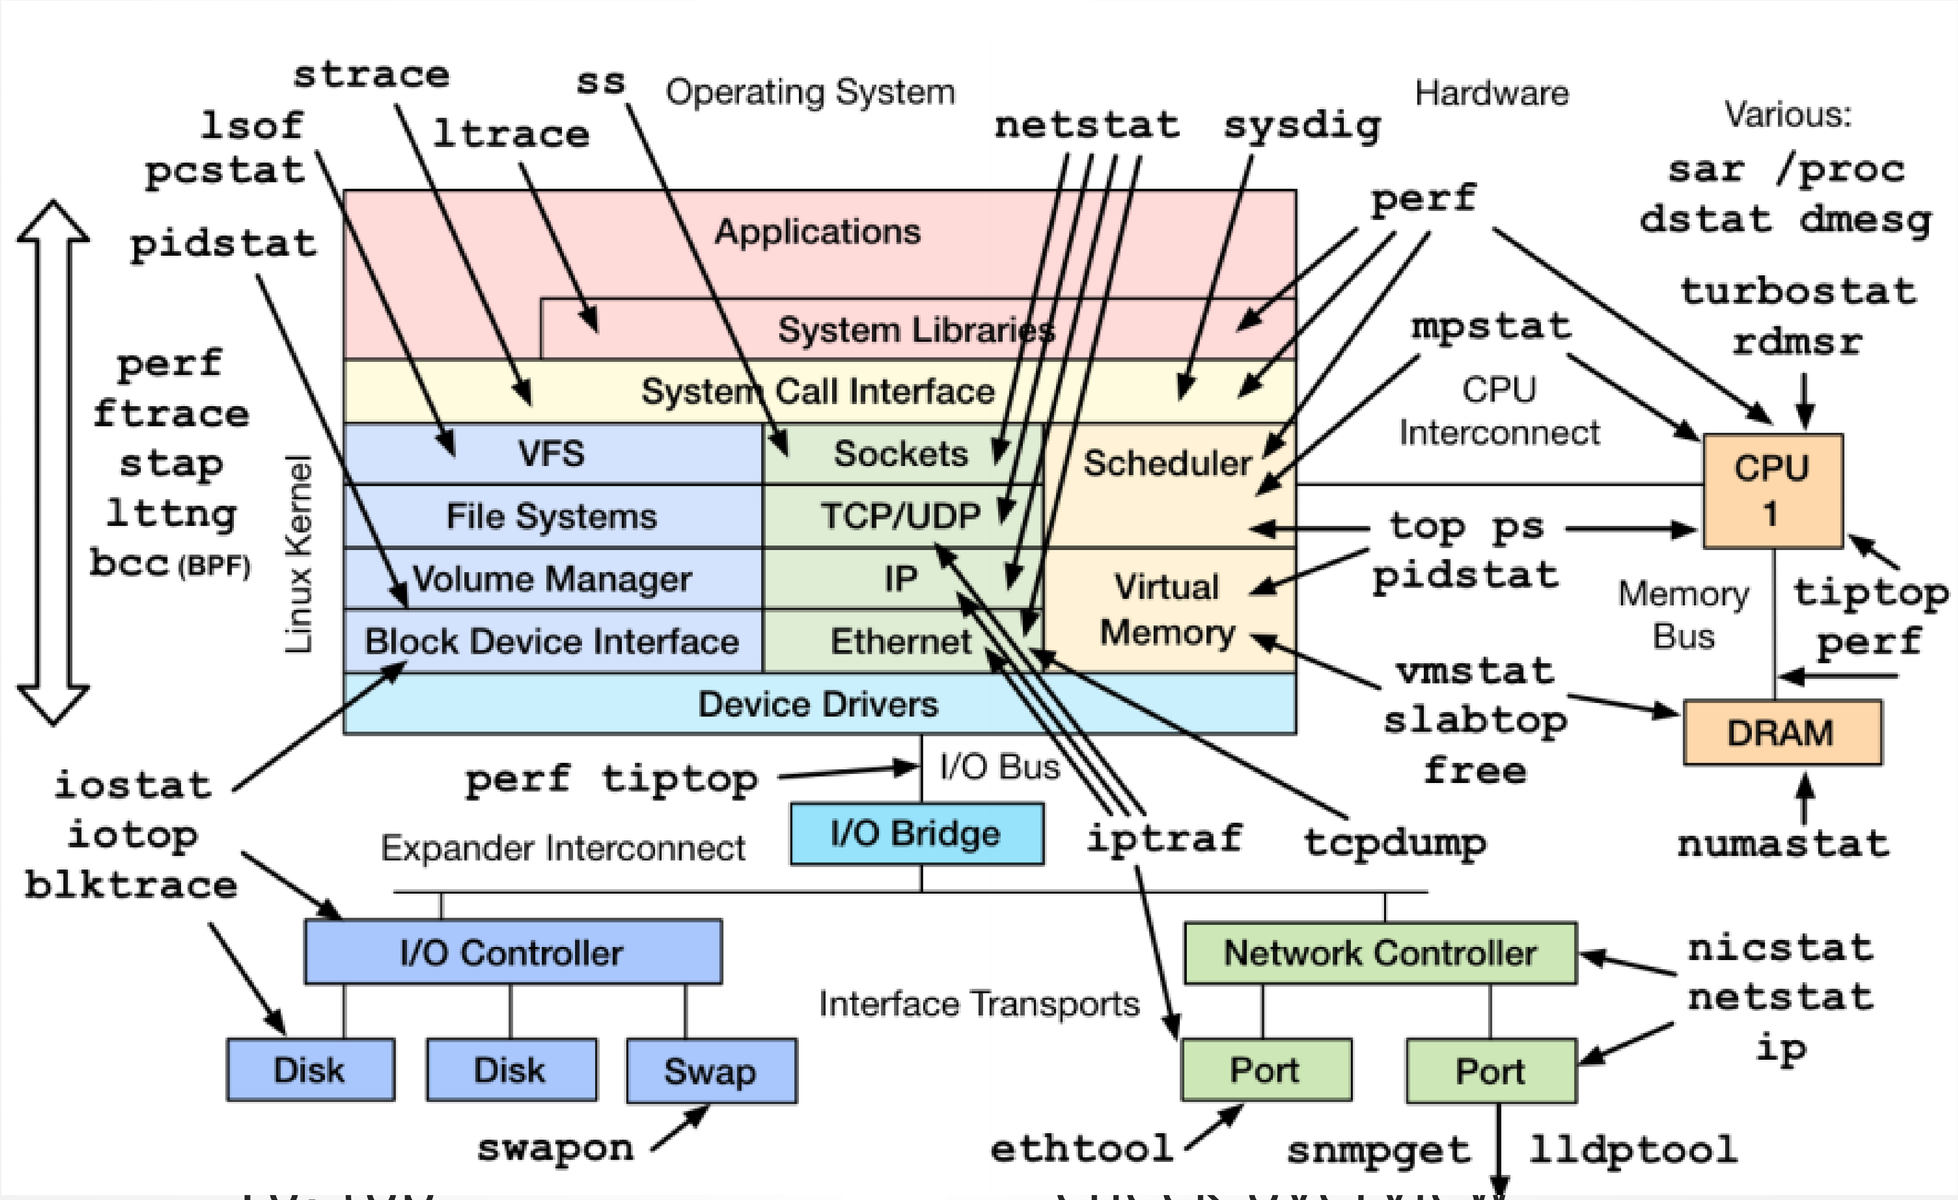

http://www.brendangregg.com/linuxperf.html

www.163yun.com

如何优化 Kubernetes？

网易云

Perf Analysis in 60s

- 1. uptime
- 2. dmesg | tail
- 3. vmstat 1
- 4. mpstat -P ALL 1
- 5. pidstat 1
- 6. iostat -xz 1
- 7. free -m
- 8. sar -n DEV 1
- 9. sar -n TCP,ETCP 1
- 10. top

- load averages
- kernel errors
- overall stats by time
- CPU balance
- process usage
- disk I/O
- memory usage
- network I/O
- TCP stats
- check overview

http://techblog.netflix.com/2015/11/linux-performance-analysis-in-

如何优化 Kubernetes？

网易云

举个栗子

- netstat/sar 网络监控

```
TcpExt:
    867 SYN cookies sent
    1063 SYN cookies received
    2470 TCP sockets finished time wait in fast timer
    25 delayed acks sent
    Quick ack mode was activated 150 times
    36984 times the listen queue of a socket overflowed
    36984 SYNs to LISTEN sockets dropped
    30 packets directly queued to recvmsg prequeue.
```

- 重启时发现异常全连接队列太小
- sar -n DEV,ETCP 1 通常会有很高的 retrans

如何优化 Kubernetes？

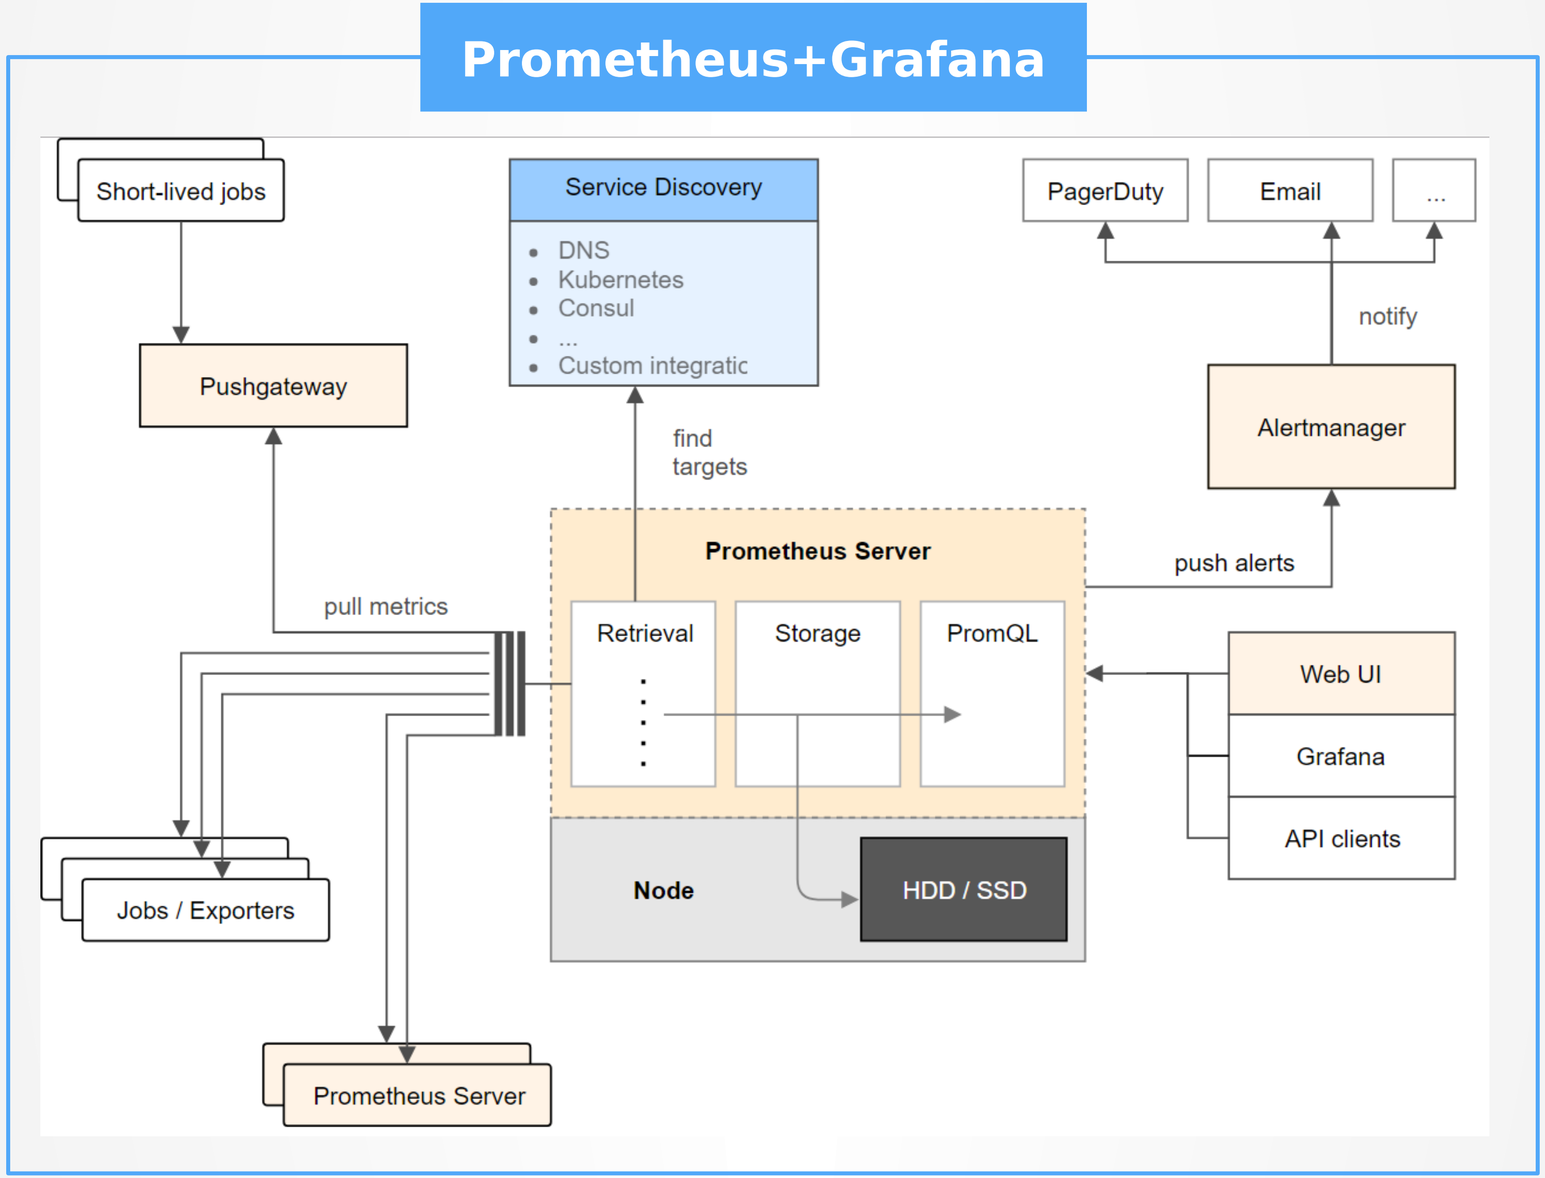

如何优化 Kubernetes？

Prometheus+Grafana

如何优化 Kubernetes？

网易云

Prometheus+Grafana

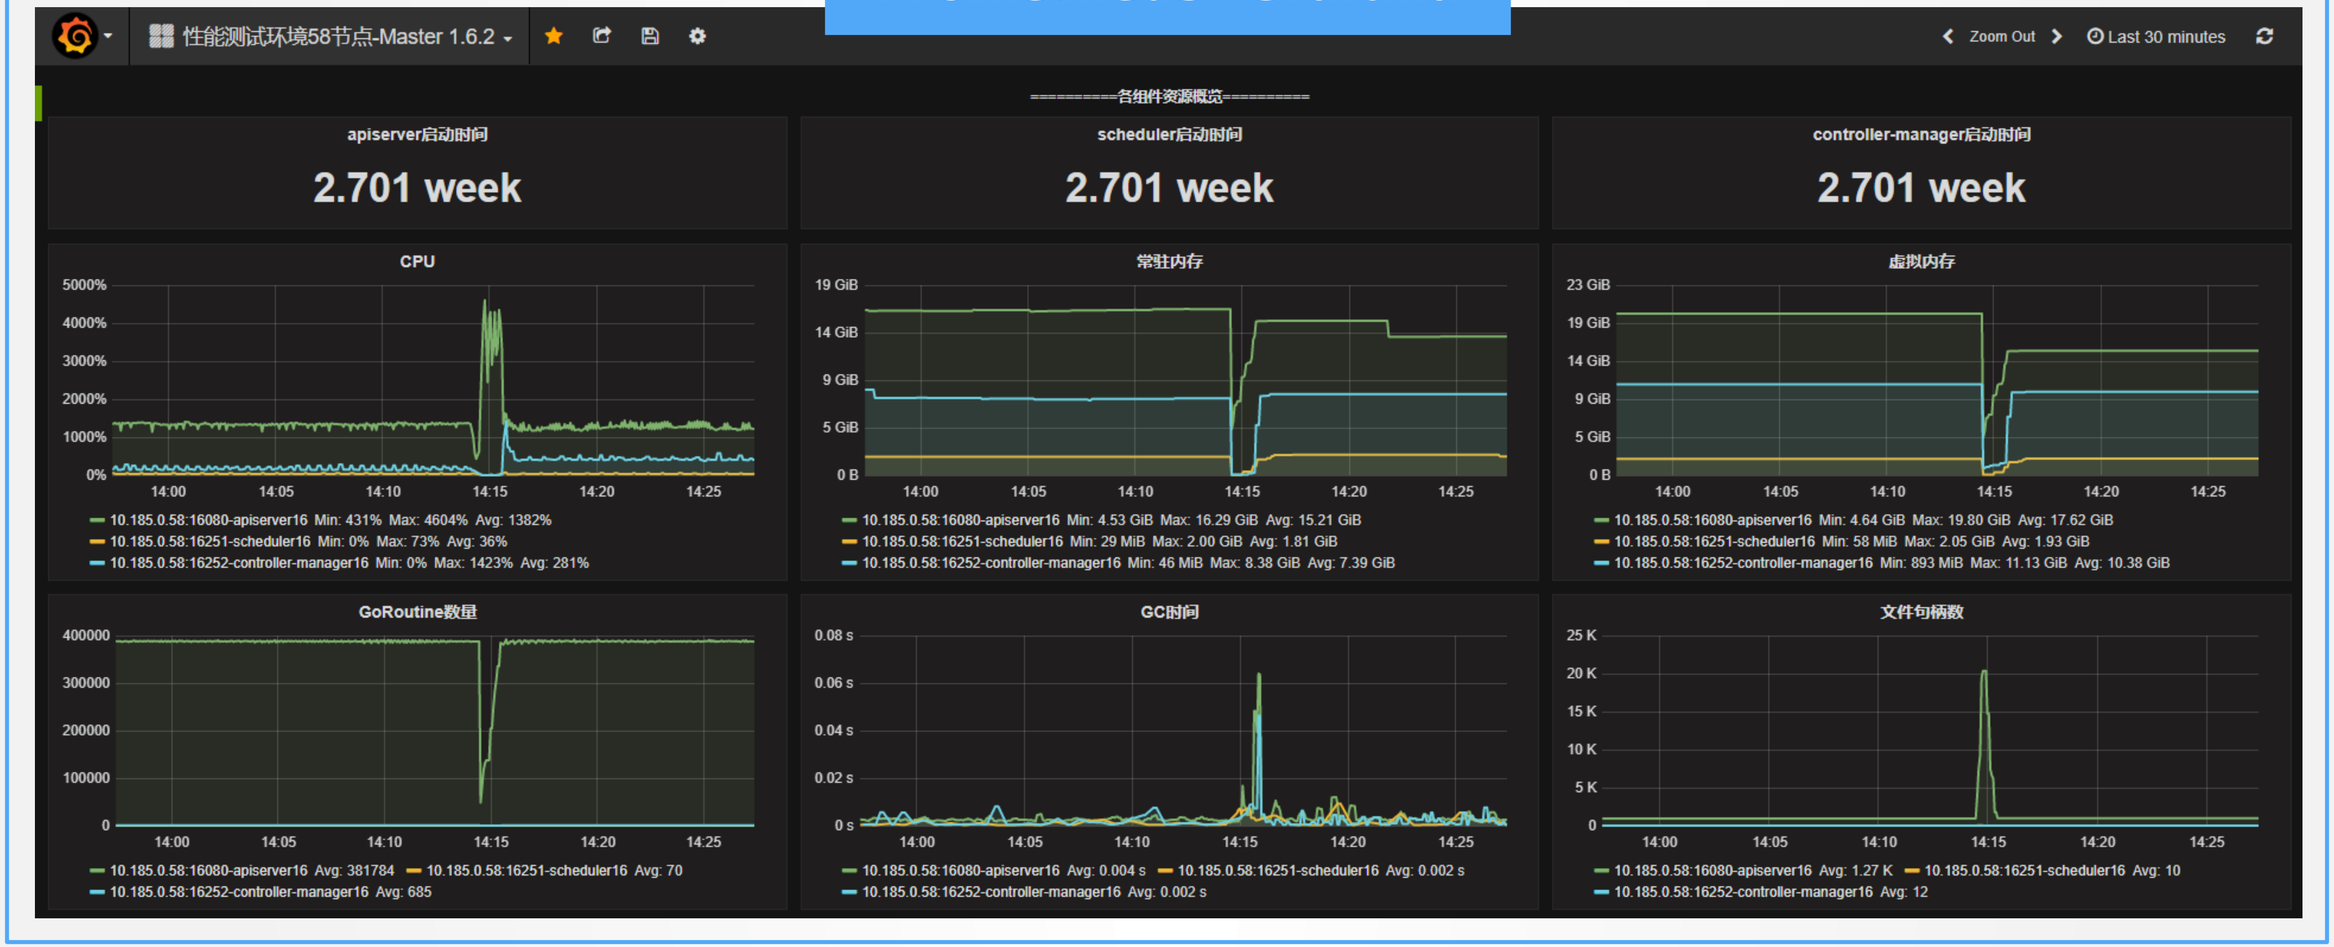

如何优化 Kubernetes？

Prometheus+Grafana

- 增加多种 metrics
- apiserver 与 etcd 访问的延迟（operation&resource）
- apiserver 流控比例
- Controller manager Sync 延迟统计（resource）
- Controller manager 队列饱和度
- Scheduler 队列饱和度
- ……

如何优化 Kubernetes？

apiserver 响应码统计

- 例如： APIServer 响应码统计
- 背景： Node – 2.5w / Pod – 15w
- 操作：重启 APIServer
- 现象：
- - 平时主要是 200(绿色)， 4600 个每秒
- - 重启 429(蓝色) 异常增高，最多近 2w 个
- - 有段时间没有 200 的响应
- - 重启时间长达近 7 分钟

不符合我们的性能通过标准
(重启 / 升级停服时间 <3min)

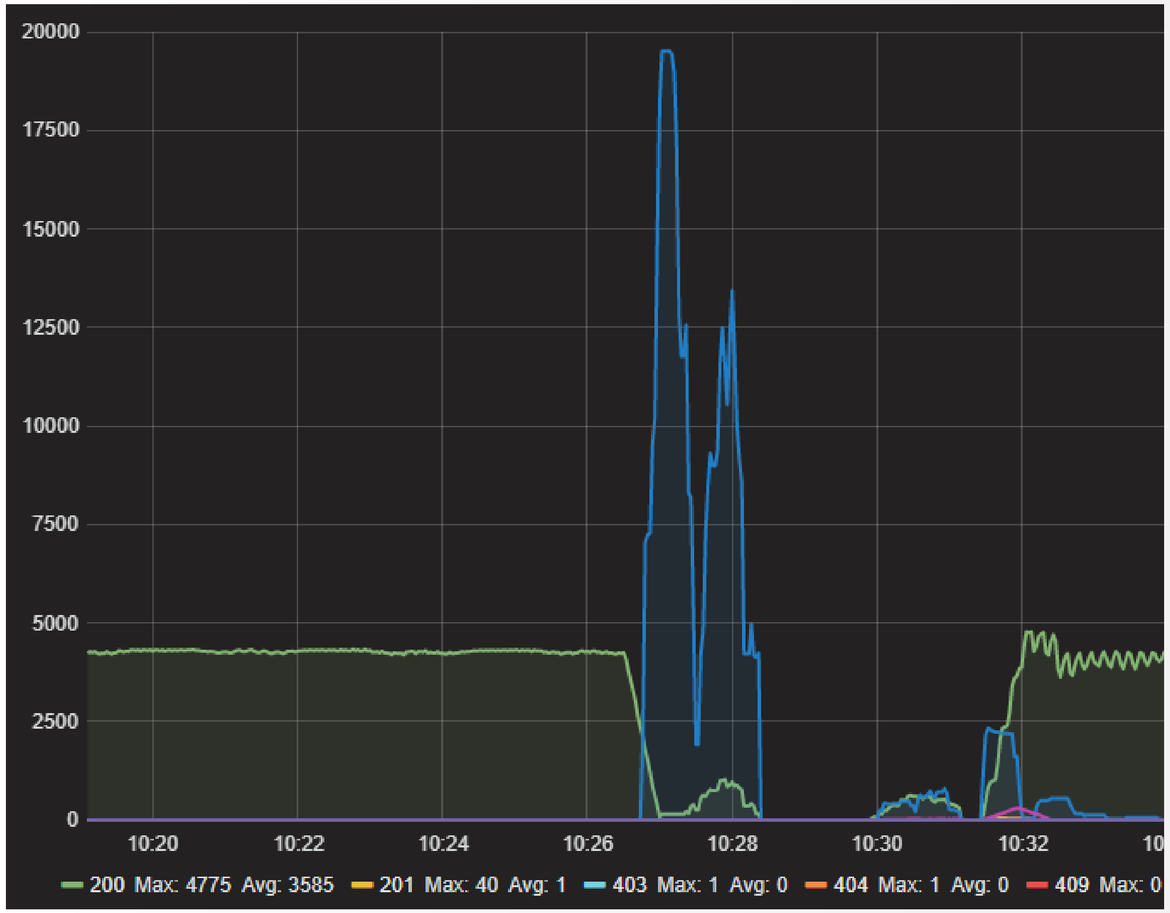

如何优化 Kubernetes？

流控优化

- 响应码 429 – 流控
- 默认流控重试时间 1s
- 机理：重启时所有 client 需要重新 list&watch 导致并发请求量过高（包含 boostrap controller），超过流控。超过流控之后，返回响应码 429，同时在响应头里添加 Retry-After 告诉 client 1s 之后再试，造成 APIServer 长时间过载。

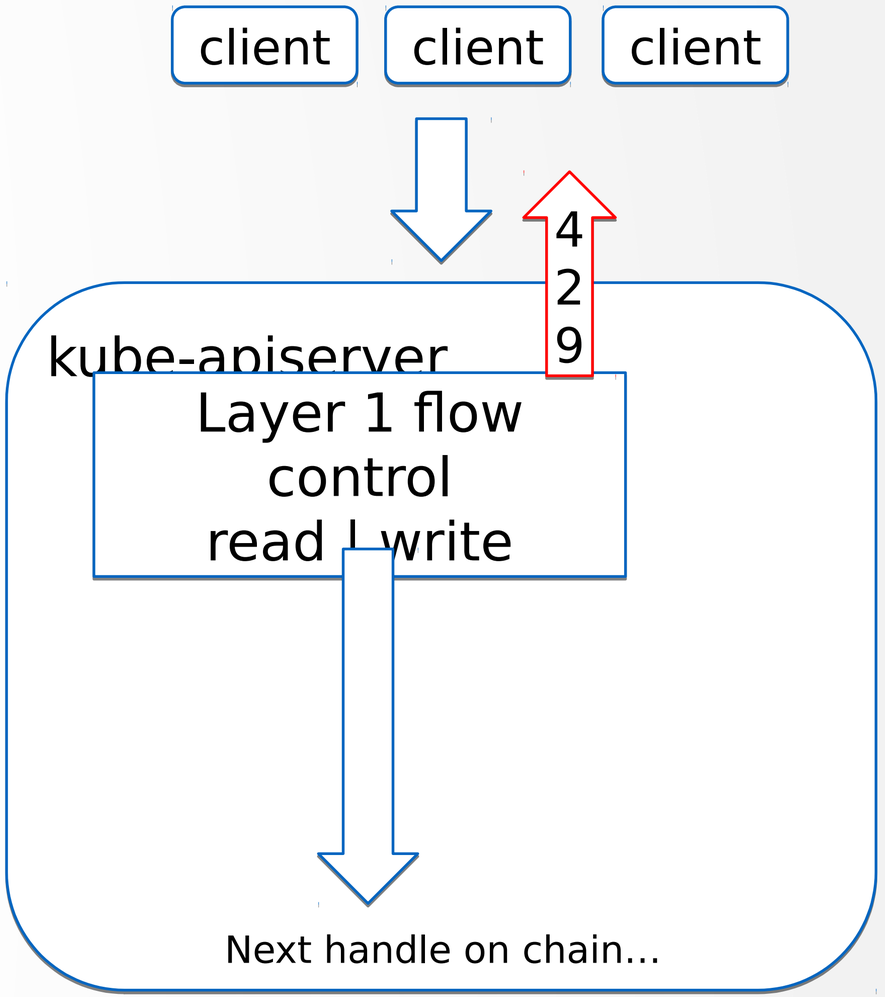

如何优化 Kubernetes？

流控优化

- 多级流控：在读写流控的基础上，根据 UserAgent、Resource、Verb 进行细粒度流控
- 例如：通过 UserAgent，限制 kubelet，优先允许 Master 组件初始化 (APIServer Bootstrap Controller、其他 Controller 和 Scheduler 等)

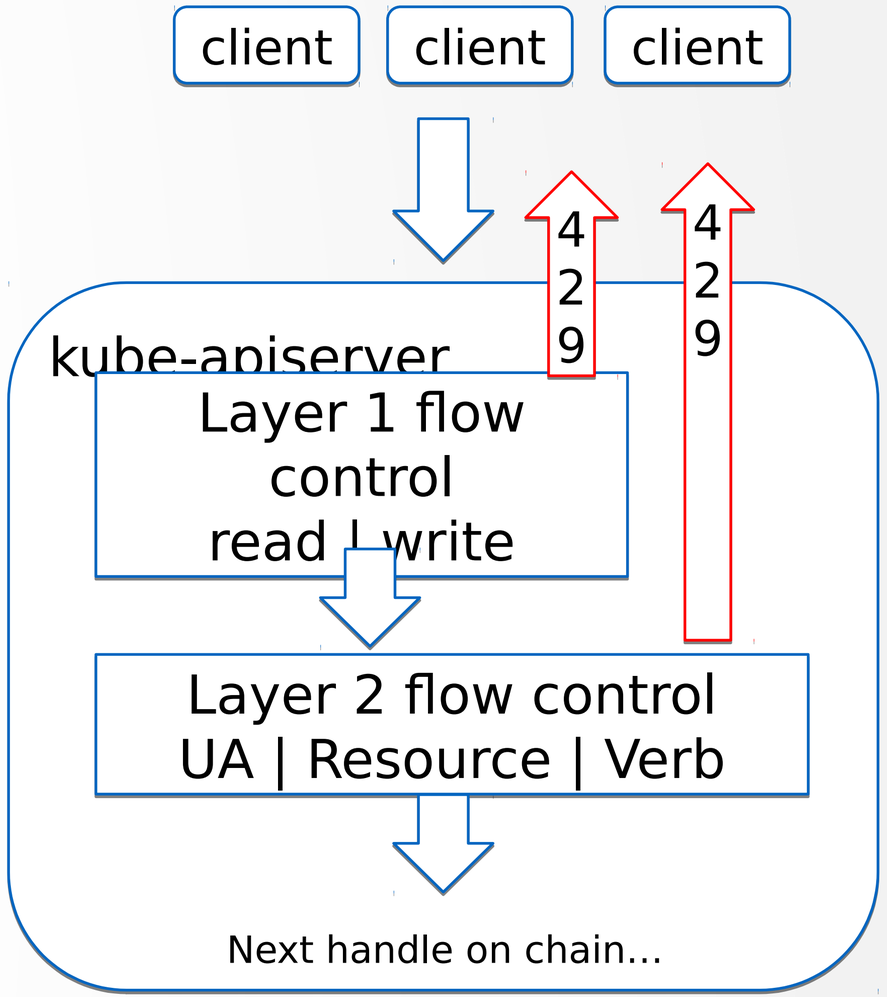

如何优化 Kubernetes？

流控优化

- 拥塞控制：静态 Retry-After 改为动态值，根据系统当前繁忙程度调节 1 到 8s （token bucket）

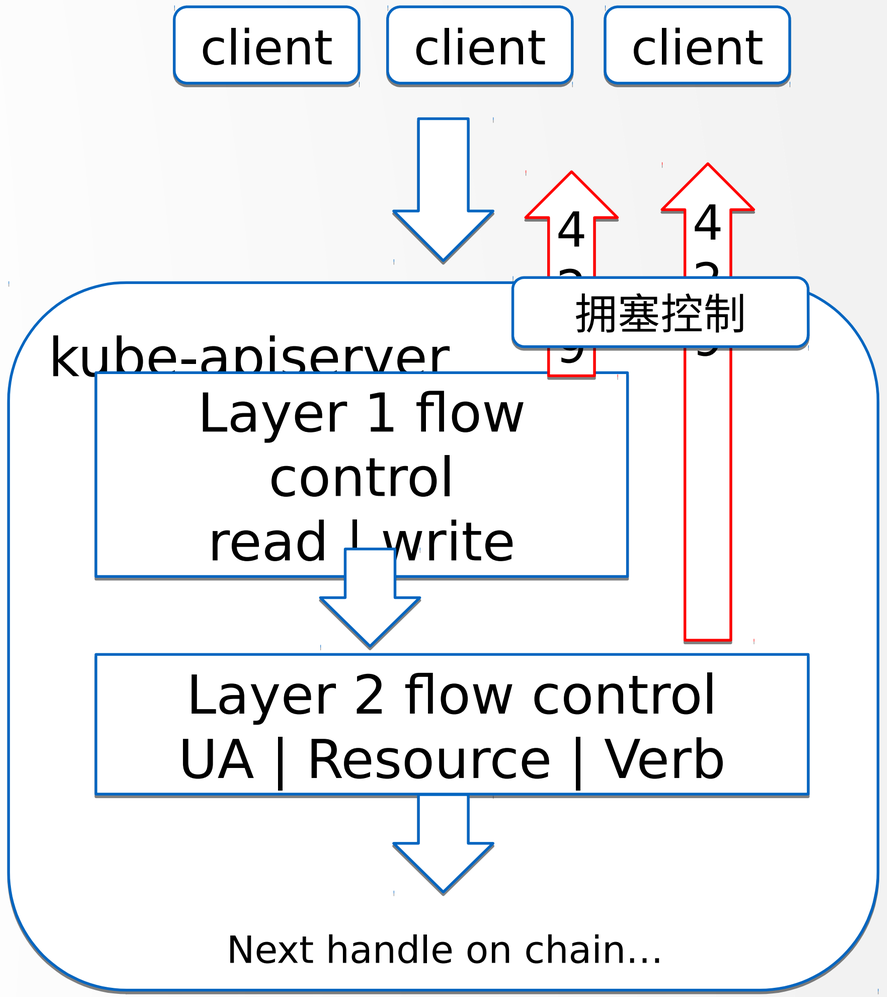

如何优化 Kubernetes？

流控优化

- 拥塞控制：静态 Retry-After 改为动态值，根据系统当前繁忙程度调节 1 到 8s （token bucket）
- 算法：初始化时间窗口为 1s、容量 2^{10} 的 bucket，每次被流控尝试拿 Token
- - 可用量 >1/2，返回 1s
- - 可用量 > ¼，返回 2s
- - 可用量 > 1/8，返回 4s
- - 可用量不足或者不可用，返回 8s

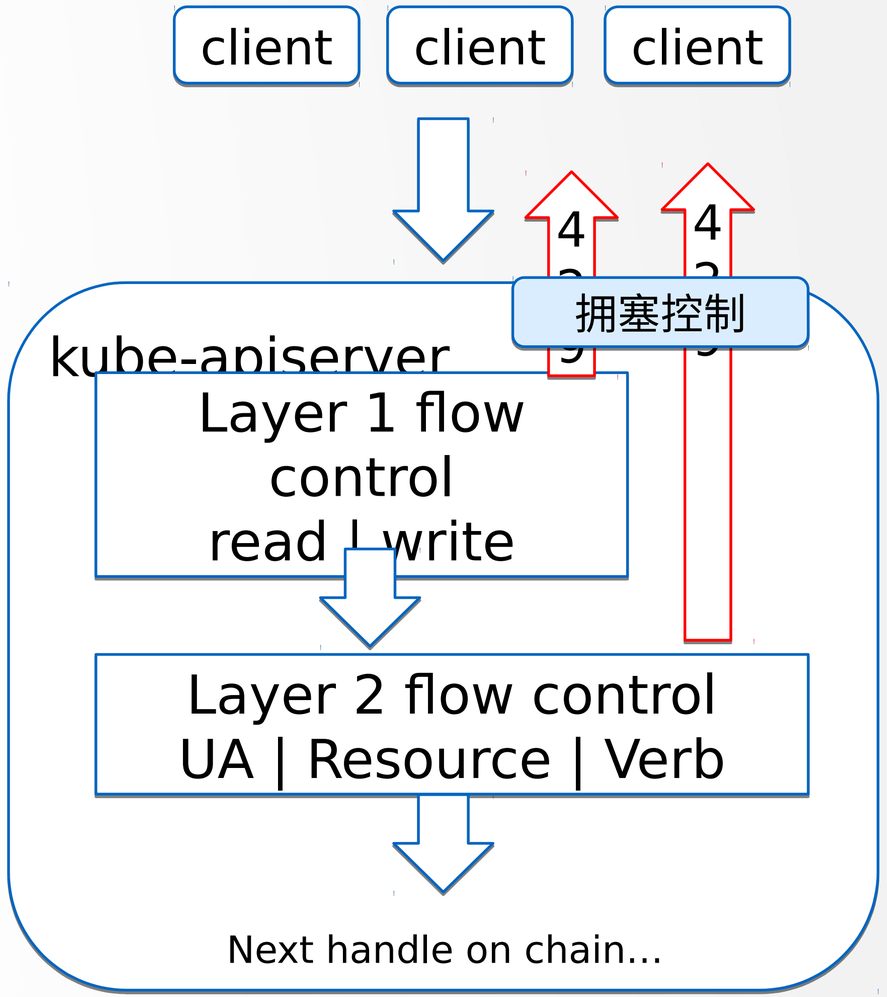

如何优化 Kubernetes？

网易云

apiserver 响应码统计

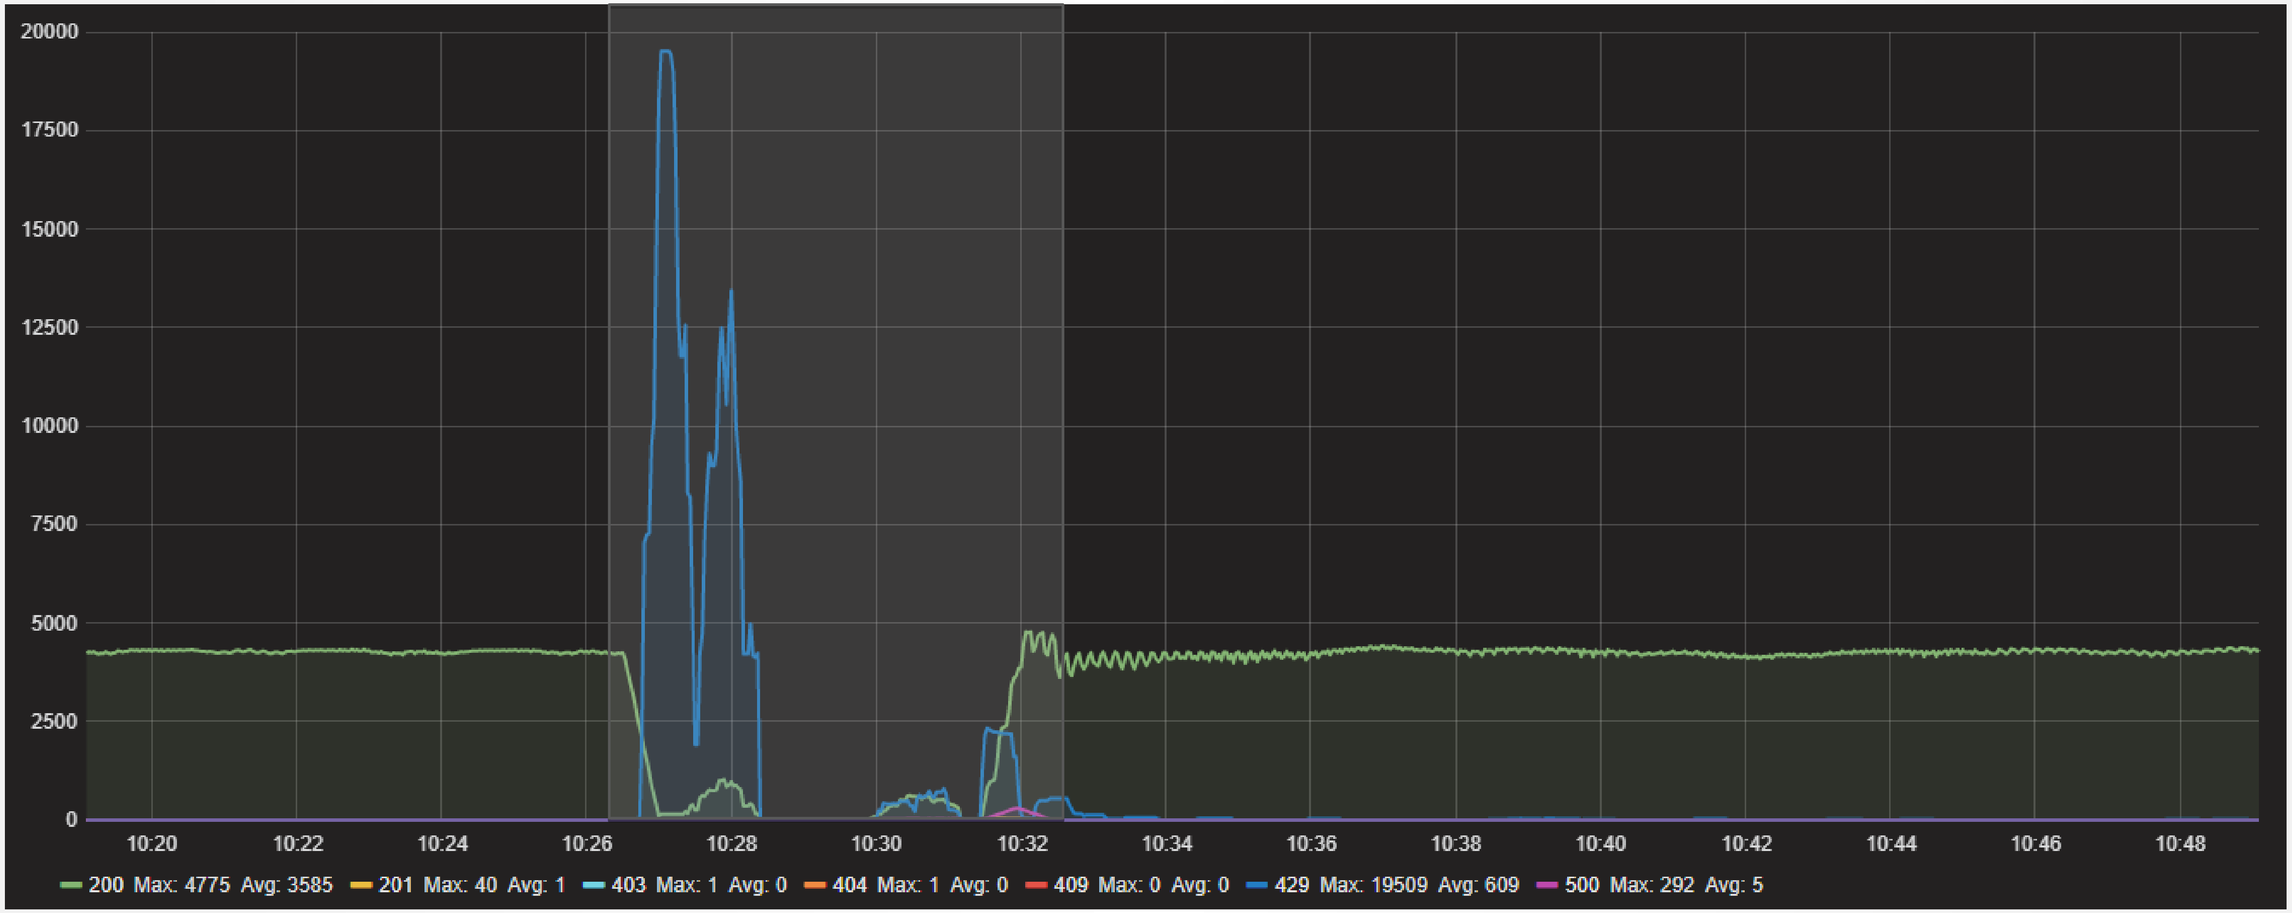

如何优化 Kubernetes？

apiserver 响应码统计

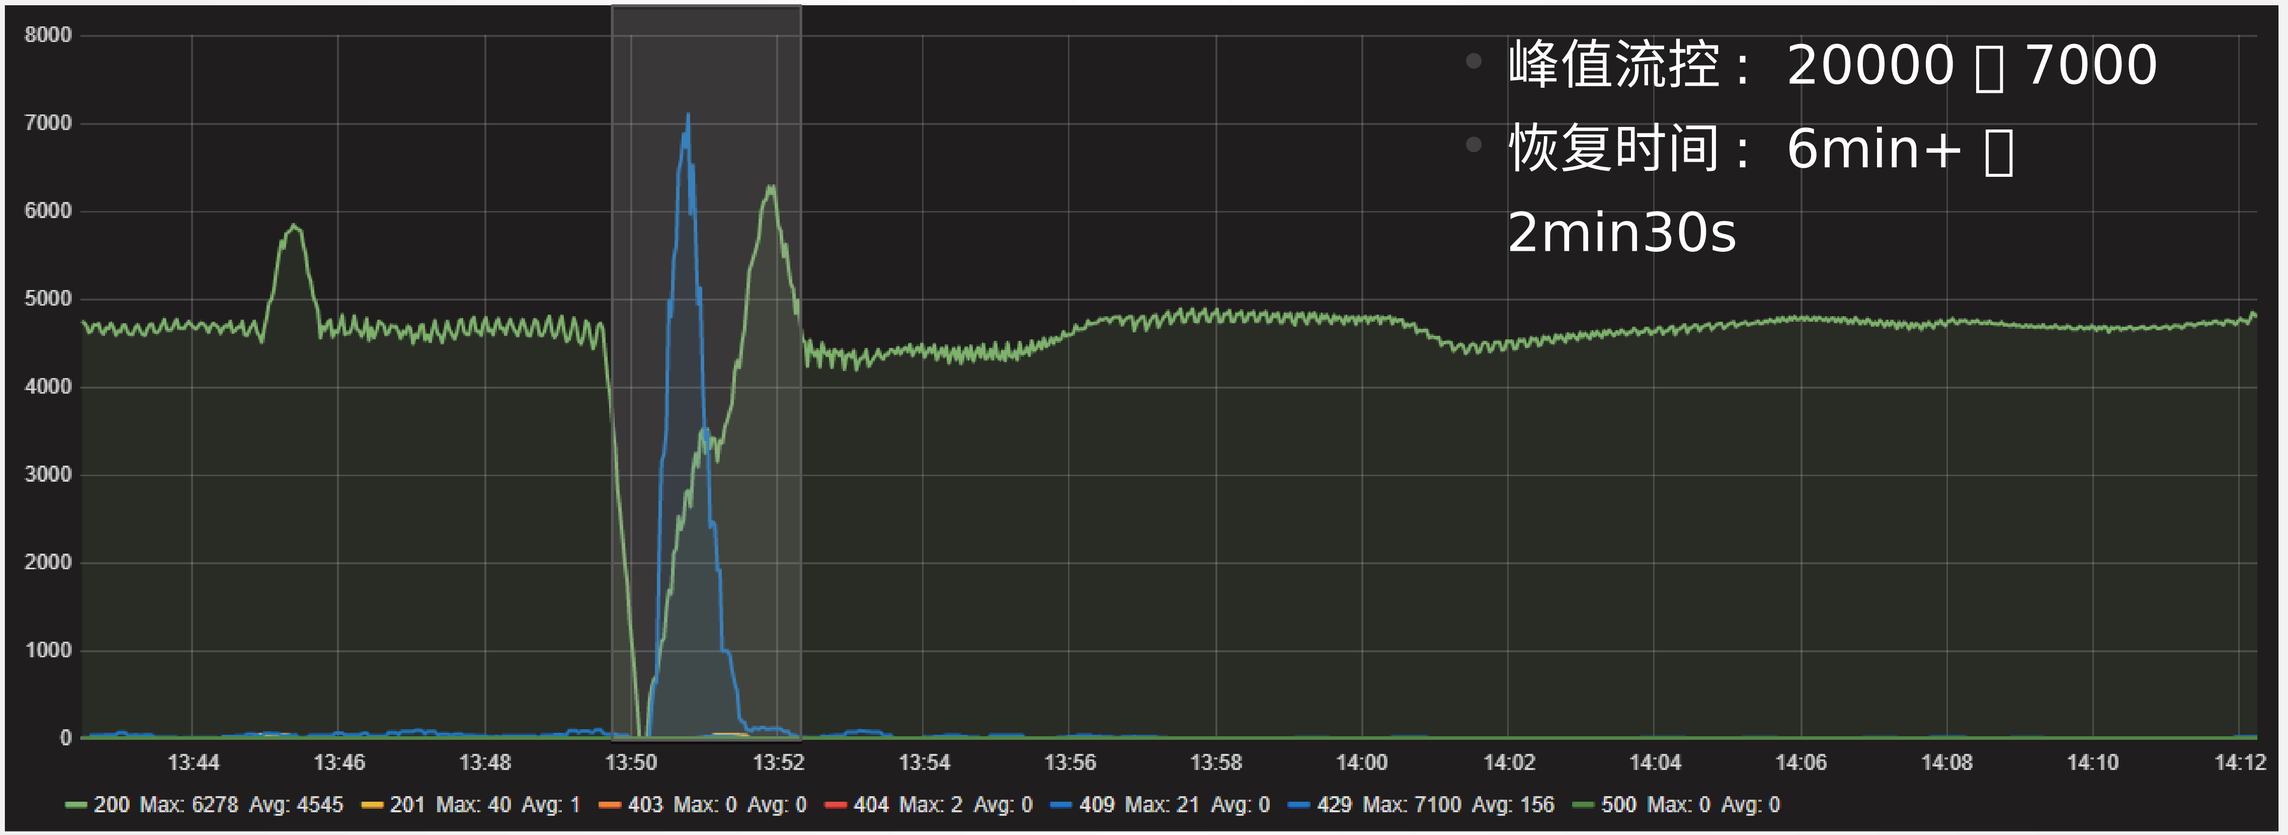

- 峰值流控： 20000 → 7000
- 恢复时间： 6min+ → 2min30s

如何优化 Kubernetes？

另一个例子

- Controller manager Sync 延迟统计（resource）
- 什么是 Sync？
- - 控制器在处理一种资源的过程称为一个 Sync（增删改）
- - 每隔一段时间 (普通资源 12 ~ 24 小时、 Namespace 5 min, Endpoint 30s) 全量同步一次 (防止漏处理，来自 etcd2 的毛病)

- 泡一杯咖啡坐等结果……

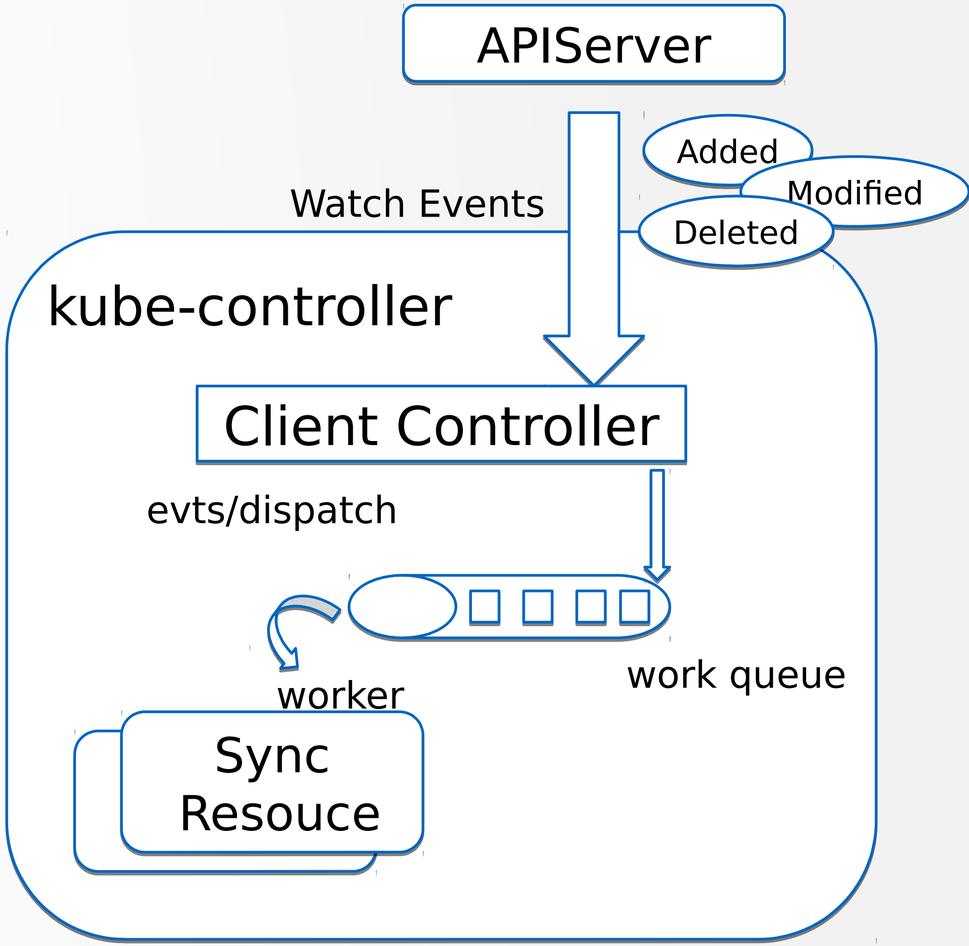

如何优化 Kubernetes？

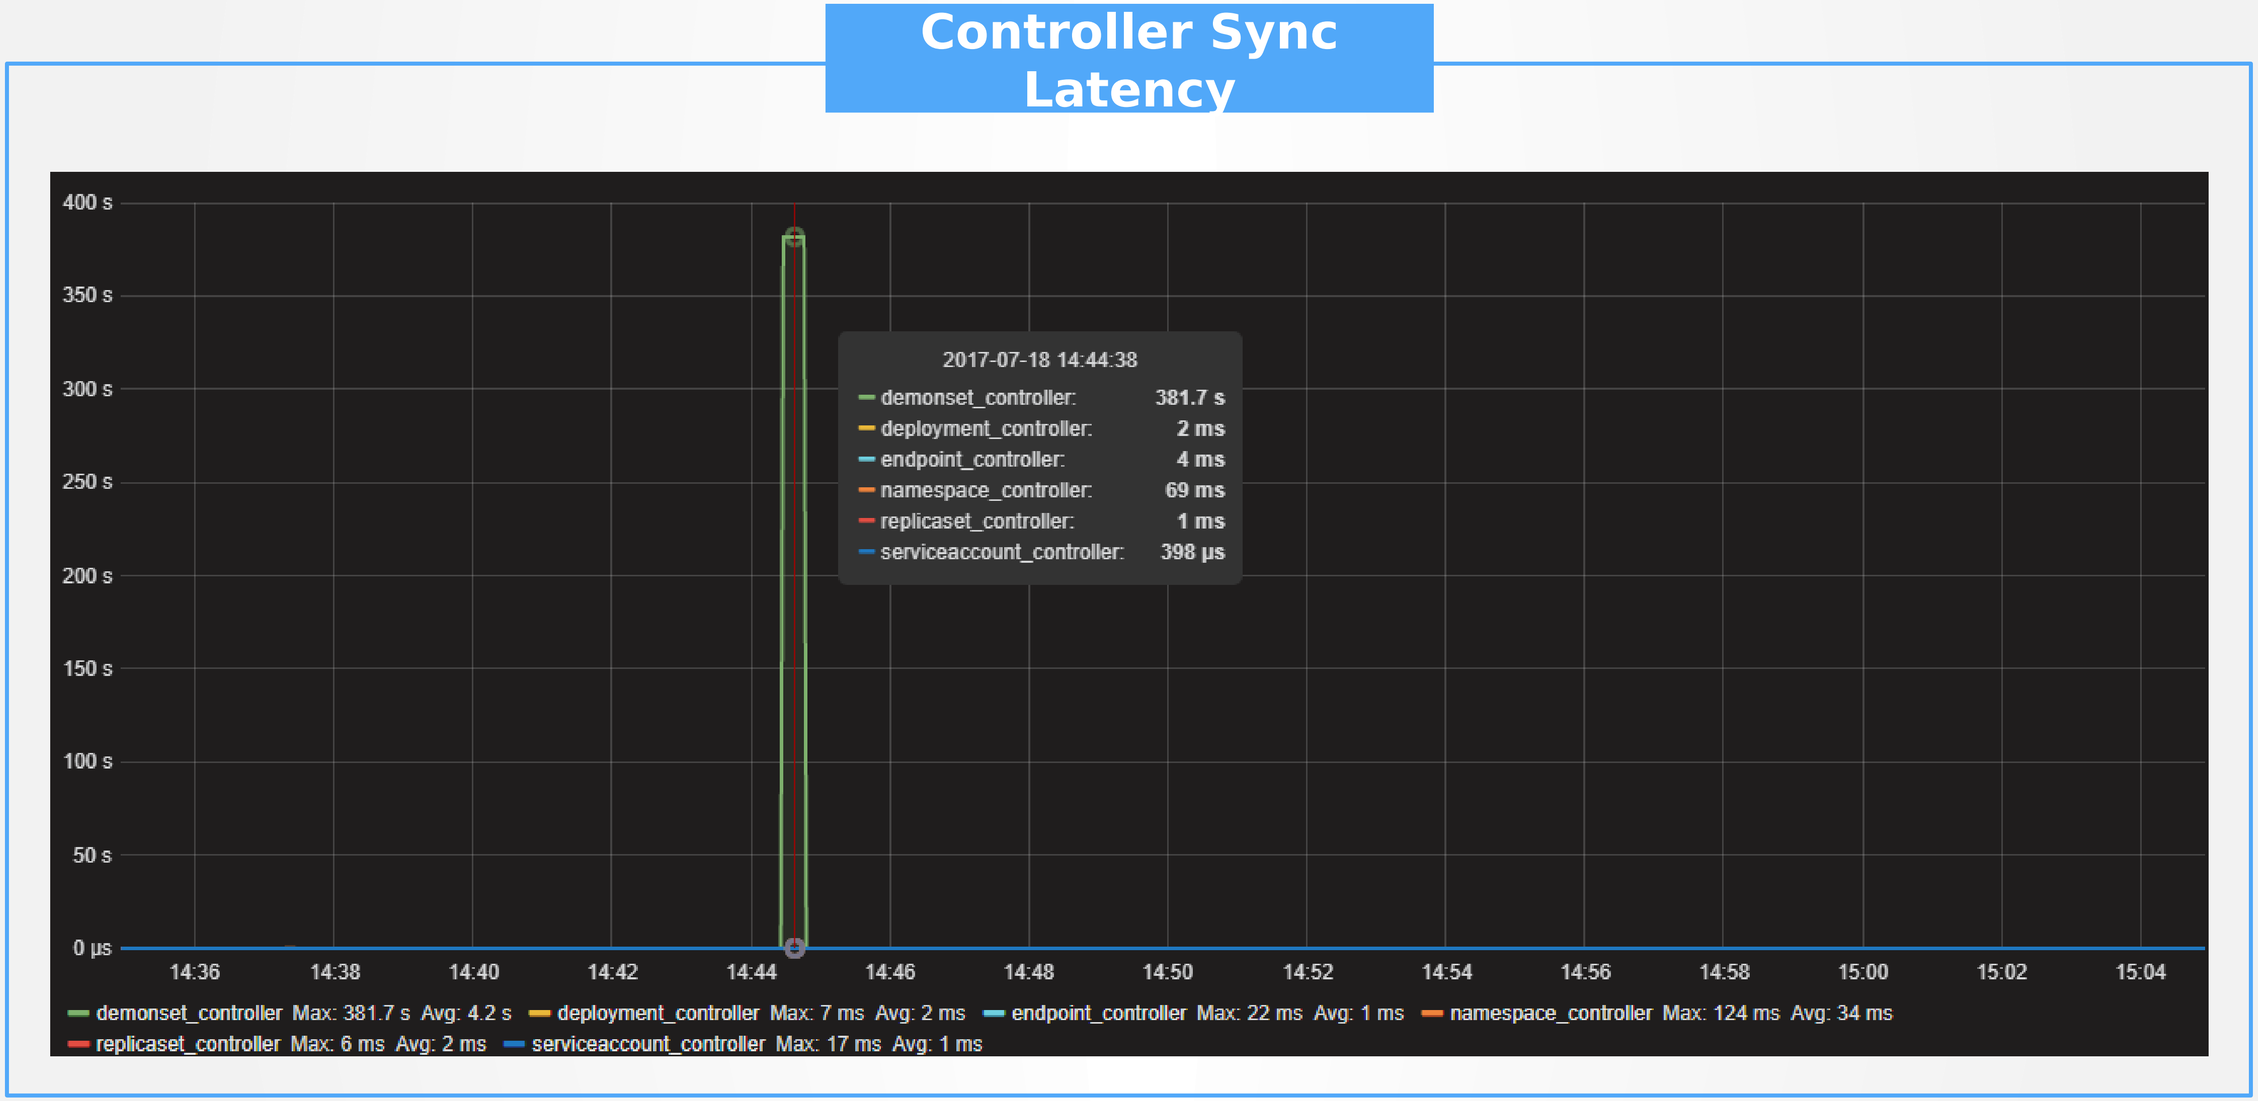

如何优化 Kubernetes？

网易云

Controller Sync Latency

- 发现 DaemonSet Controller 同步时间异常
- 原因： 每次 DaemonSet 同步时，循环 node 时，在 node 内部重复 List Pod，时间复杂度 O(PodNum*NodeNum*DaemonSetNum)
- 能否优化过程： 过程无法去除，因为 DaemonSet Controller 需要检查 node 可调度状态，那么就必须取得 Node 上所有 Pod 的状态
- 优化： 空间换时间，对 pod list 一次，进行分组， node 只根据检查调度到自身的 pod，空间复杂度 O(N)，时间复杂度 O(max(P,N)*D)
- 优化： 加速 Pod List 的过程
- 优化： 增加 Field 索引
- 结果： DaemonSet 峰值去除

如何优化 Kubernetes？

网易云

加速 Pod List 过程

- 原理： Lister 接口接收 LabelSelector，但此时 Pod 传入 LabelSelector 为空，则无需经过 Label 的比较
- 实现： API Expansion 机制， k8s 允许我们自定义资源操作接口，而不对原生逻辑造成侵入，不会影响 client 代码生成
- 方式： $SRC/pkg/client/listers/$VERSION/${RESOURCE}_expansion.go

如何优化 Kubernetes？

网易云

加速 Pod List 过程

- 实现： API Expansion 机制
- 方式： $SRC/pkg/client/listers/$VERSION/${RESOURCE}_expansion.go

```
// PodListerExpansion allows custom methods to be added
to
// PodLister.
type PodListerExpansion interface {
    ListAll() ([]*v1.Pod, error)
}

// ListAll provide a fast path to get pods without
selector.
func (l *podLister) ListAll() ([]*v1.Pod, error) {
    src := l.indexer.List()
    dst := make([]*v1.Pod, len(src))
    for _, m := range src {
        dst = append(dst, m.(*v1.Pod))
    }

    return dst, nil
}
```

如何优化 Kubernetes？

Prometheus+Grafana

- 不是万能
- 不足
- - 采样抹掉毛刺 (10s 踩一次)，漏掉异常波动
- - 平滑算法，可能因为采样区间问题导致图像完全不一致，造成错误判断

如何优化 Kubernetes？

采样 + 平滑算法 bug

www.163yun.com

如何优化 Kubernetes？

网易云

性能剖析

- 系统层面： perf、 systemtap、 bcc
- 应用层面： go tool pprof

如何优化 Kubernetes？

网易云

系统层：举个例子

- 发现 Kubemark CPU 消耗太高 (> 50%)
- go tool pprof 能够采集到的 CPU 消耗很低 (10%+)
- 猜测： 可能是 kernel 过程耗时过多 CPU
- 工具： perf top -p `pidof kubemark`

如何优化 Kubernetes？

```
Samples: 94K of event 'cpu-clock', Event count (approx.): 9389641316
Overhead  Shared O  Symbol
  35.24%  [kernel]  [k] copy_page_range
   4.15%  [kernel]  [k] unmap_page_range
   3.13%  [kernel]  [k] __x2apic_send_IPI_mask
   2.75%  [kernel]  [k] copy_page
   2.30%  [kernel]  [k] finish_task_switch
   2.28%  [kernel]  [k] __do_page_fault
   1.98%  [kernel]  [k] __lock_text_start
   1.98%  [kernel]  [k] native_write_msr
   1.53%  [kernel]  [k] vm_normal_page
   1.39%  kubemark  [.] runtime.scanobject
   1.38%  [kernel]  [k] smp_call_function_many
   1.28%  [kernel]  [k] page_remove_rmap
   1.25%  [kernel]  [k] handle_mm_fault
   1.20%  [kernel]  [k] smp_call_function_single
   1.14%  kubemark  [.] runtime.mallocgc
   1.06%  [kernel]  [k] get_page_from_freelist
   0.82%  kubemark  [.] runtime.selectgoImpl
   0.82%  [kernel]  [k] clear_page_c_e
   0.78%  [kernel]  [k] release_pages
   0.66%  kubemark  [.] runtime.siftdownTimer
   0.57%  [kernel]  [k] _raw_spin_lock
   0.53%  kubemark  [.] runtime.heapBitsSetType
   0.52%  [kernel]  [k] wp_page_copy
   0.49%  kubemark  [.] runtime.mapiternext
   0.47%  kubemark  [.] runtime.heapBitsForObject
   0.45%  [kernel]  [k] flush_tlb_page
   0.44%  kubemark  [.] runtime.memmove
```

www.163yun.com

如何优化 Kubernetes？

网易云

系统层：举个例子

- 发现 Kubemark CPU 消耗太高 (> 50%)
- go tool pprof 能够采集到的 CPU 消耗很低 (10%+)
- 猜测：可能是 kernel 过程耗时过多 CPU
- 工具：perf top -p `pidof kubemark`
- 结果：copy_page_range → copy_page → fork → os.Exec，kubemark 频繁调用 iptables 进程导致，mock 掉 iptables 调用
- 结论：系统 trace 有时能帮我们发现隐藏的问题

http://www.brendangregg.com/perf.html

如何优化 Kubernetes？

PProf 用法

- pprof 用法
- go tool pprof http://master/debug/pprof/profile
- **坑**：由于 apiserver timeout 模块，导致最多只能抓 1 分钟即被断开
- **跳坑姿势**：可以用 http method hack，伪装成 watch，离线分析
- curl –XWATCH http://master/debug/pprof/profile?seconds=XXX -o output
- go tool pprof <bin> output
- 举两个例子

https://blog.golang.org/profiling-go-programs

如何优化 Kubernetes？

pprof CPU 热点图

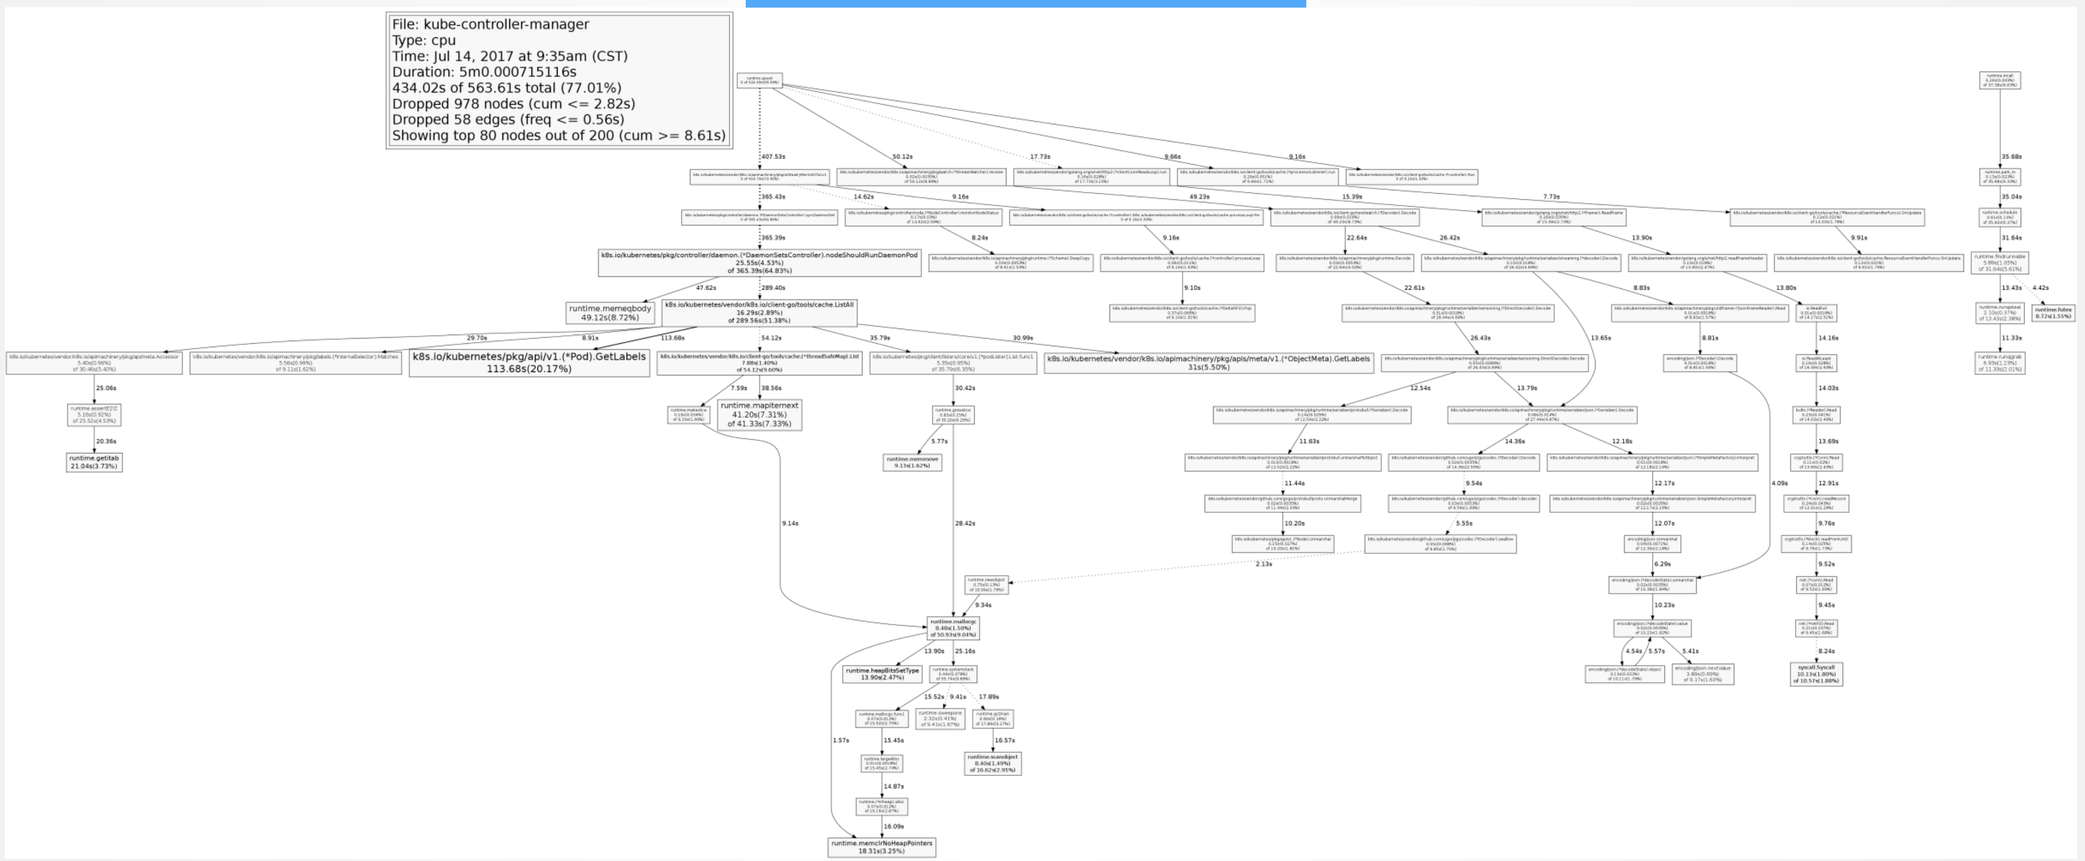

如何优化 Kubernetes？

网易云

优化前

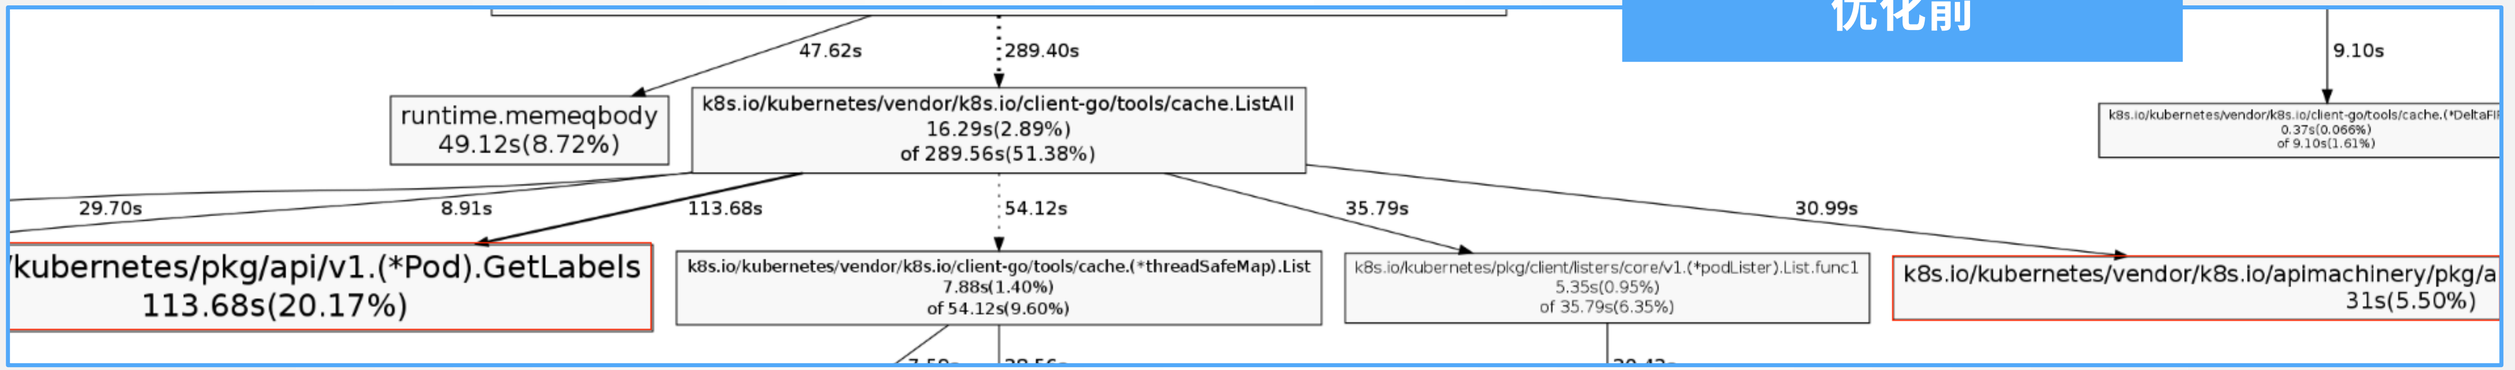

分析

- ListAll 需要通过 LabelSelector 过滤
- 通过 GetLabels 取 labels 过滤
- 大部分请求 selector 均为空
- 方案： 增加 selector.Emtpy() 时的 QuickPath

```
33 func ListAll(store Store, selector labels.Selector, appendFn AppendFunc) error {
34     for _, m := range store.List() {
35         metadata, err := meta.Accessor(m)
36         if err != nil {
37             return err
38         }
39         if selector.Matches(labels.Set(metadata.GetLabels())) {
40             appendFn(m)
41         }
42     }
43     return nil
44 }
```

如何优化 Kubernetes？

网易云

优化前

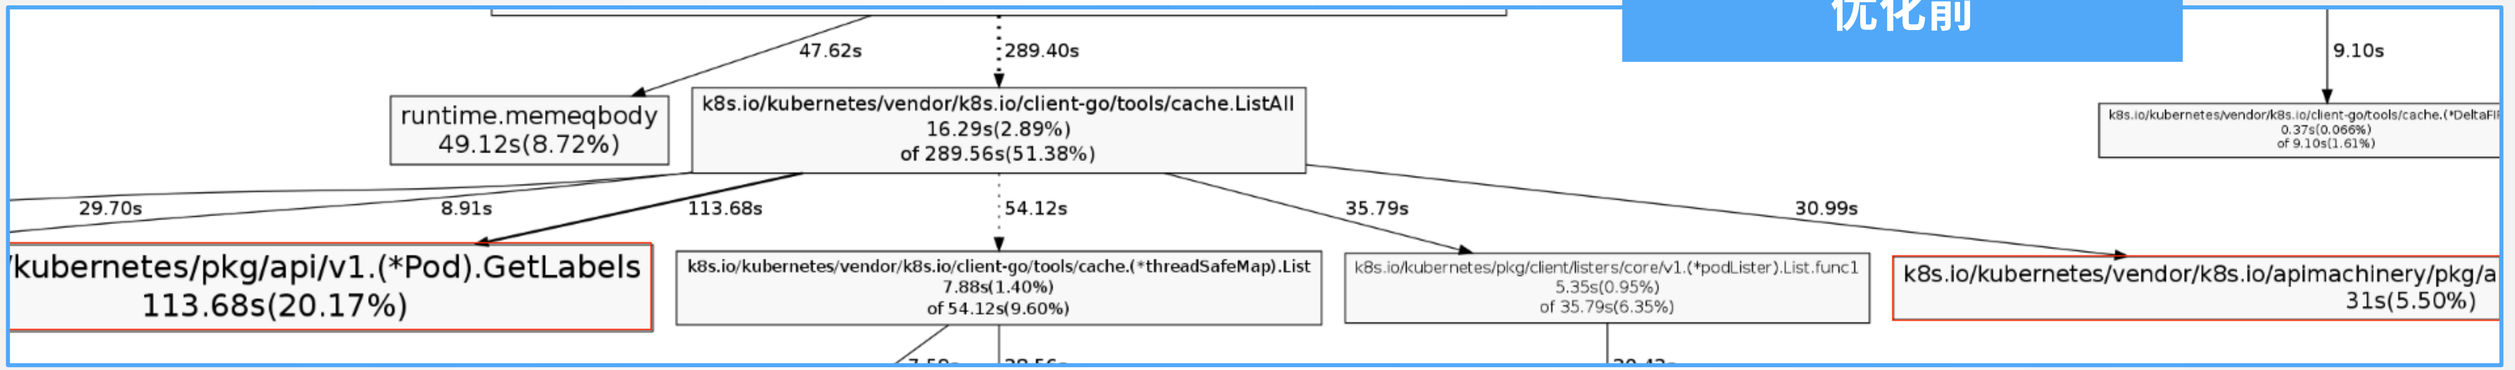

分析

- ListAll 需要通过 LabelSelector 过滤
- 通过 GetLabels 取 labels 过滤
- 大部分请求 selector 均为空
- 方案： 增加 selector.Emtpy() 时的 QuickPath

```
33 func ListAll(store Store, selector labels.Selector, appendFn AppendFunc) error {
34     for _, m := range store.List() {
35         if selector.Empty() {
36             appendFn(m)
37             continue
38         }
39         metadata, err := meta.Accessor(m)
40         if err != nil {
41             return err
42         }
43         if selector.Matches(labels.Set(metadata.GetLabels())) {
44             appendFn(m)
45         }
46     }
47     return nil
48 }
```

如何优化 Kubernetes？

优化前

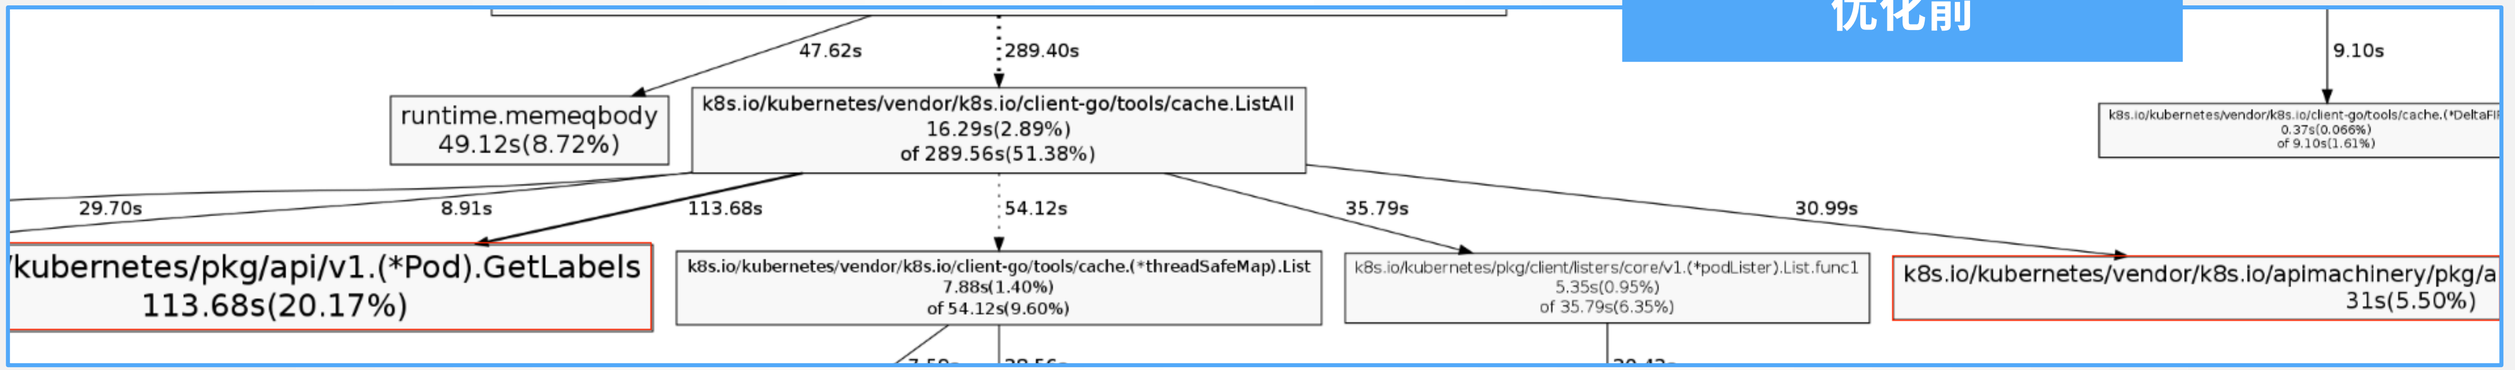

优化后

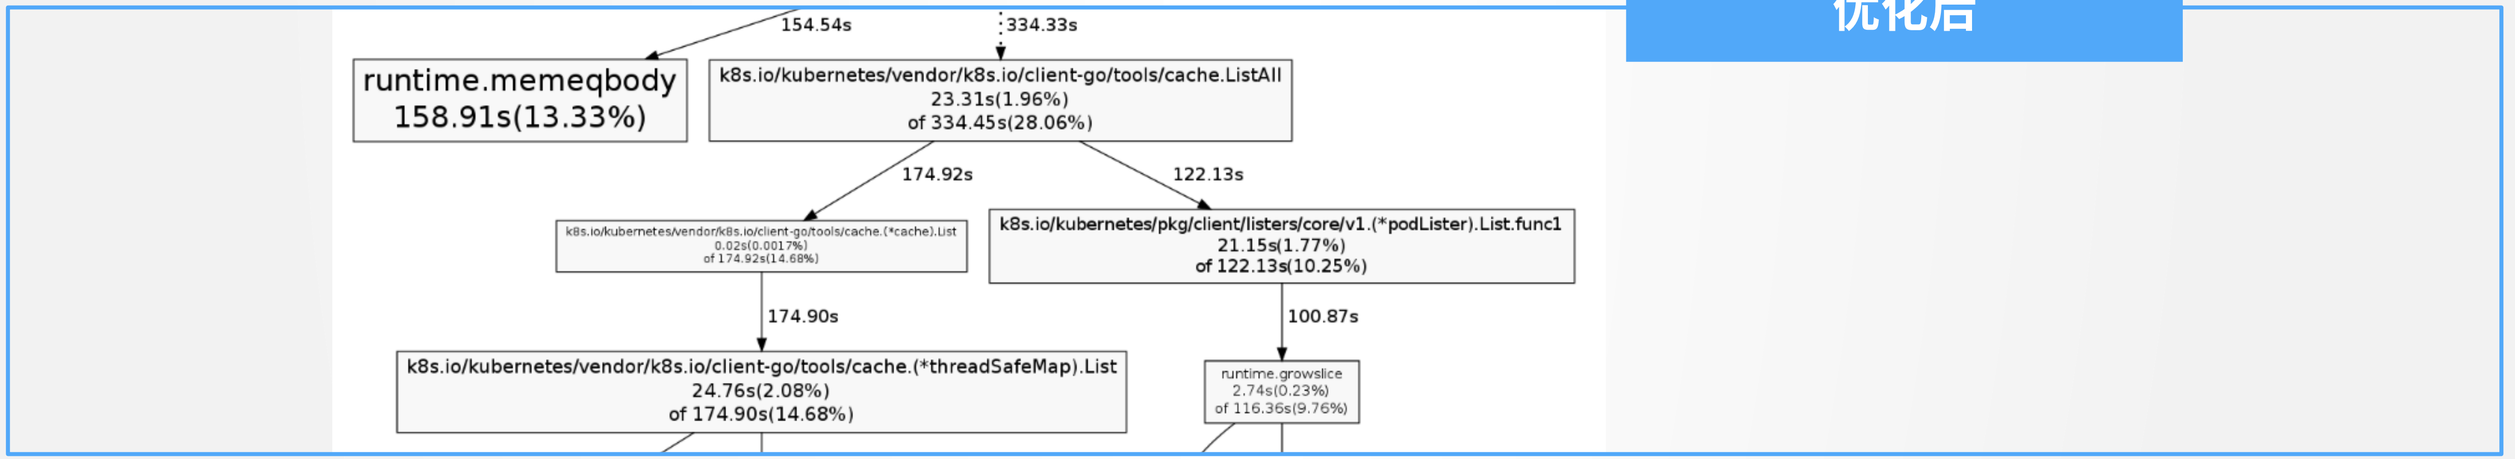

如何优化 Kubernetes？

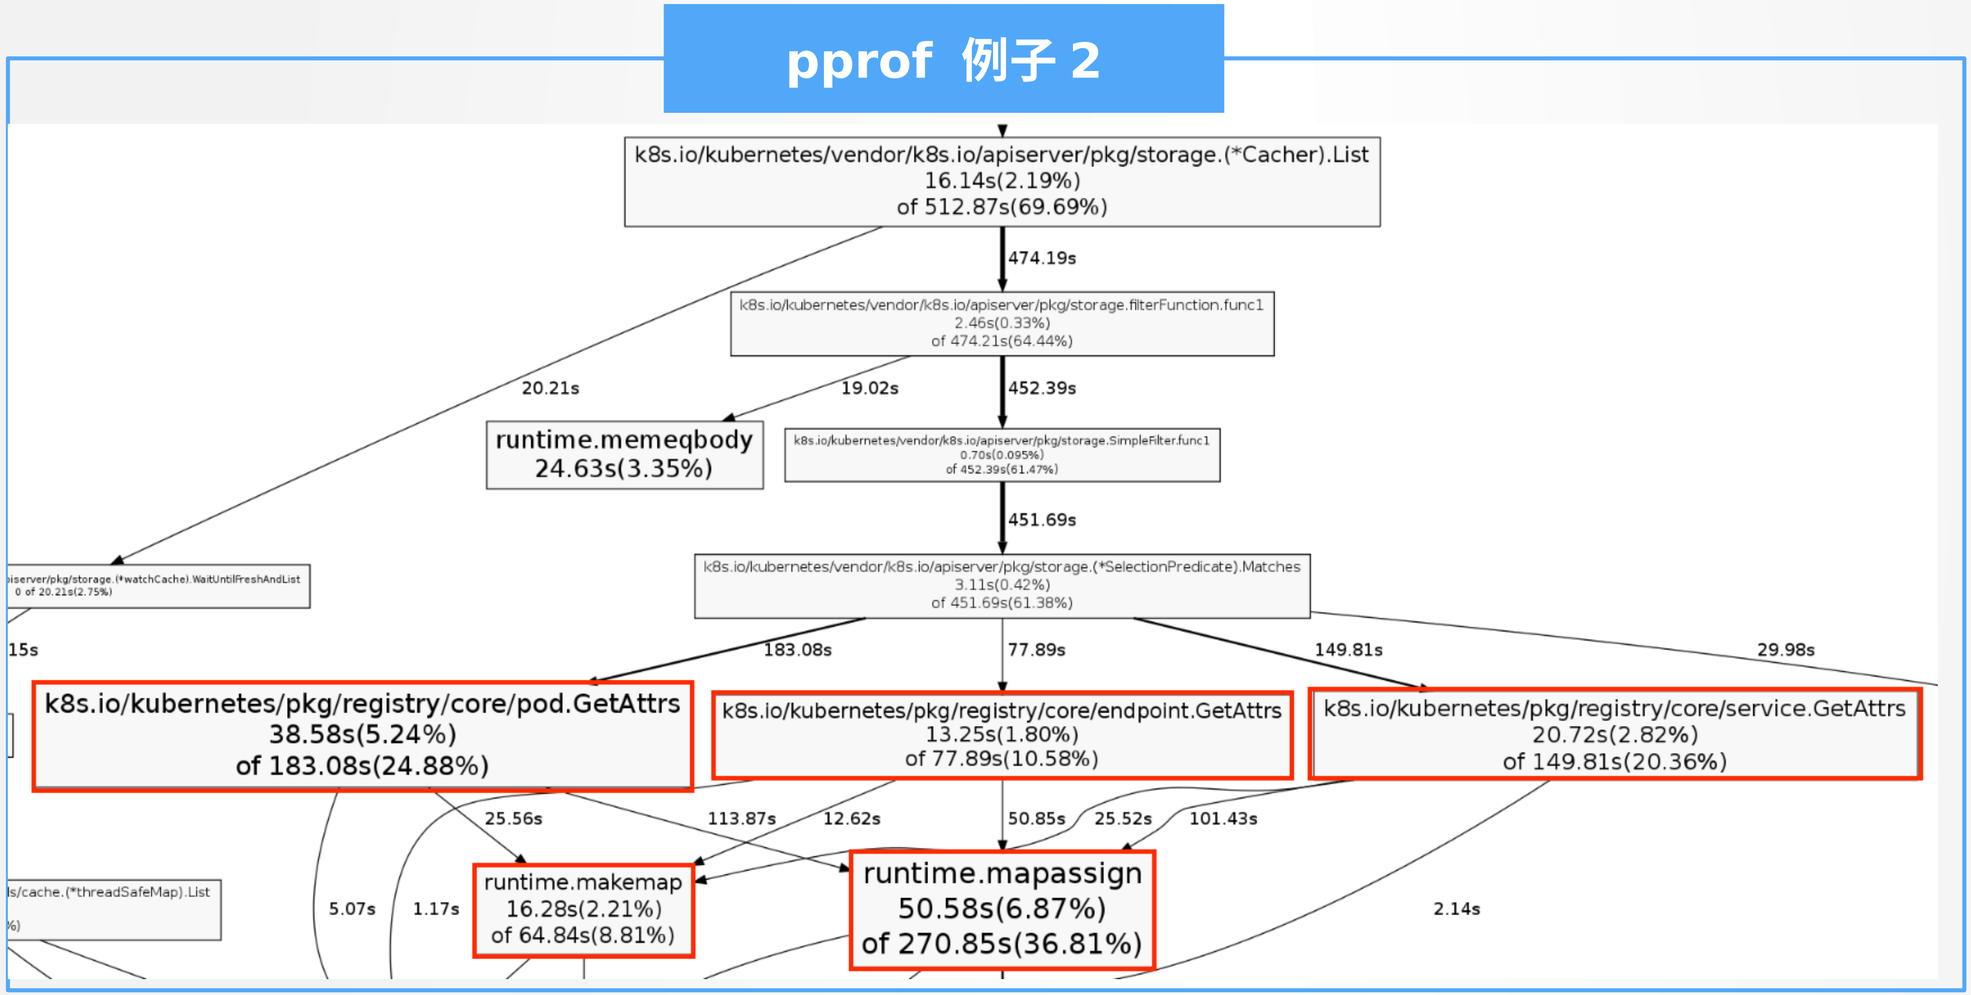

如何优化 Kubernetes？

pprof 例子 2

- **缓存层问题**
- 缓存层：缓存和聚合来自 client 的 List&Watch，防止 etcd 压力过大 (k8s1.0 引入)

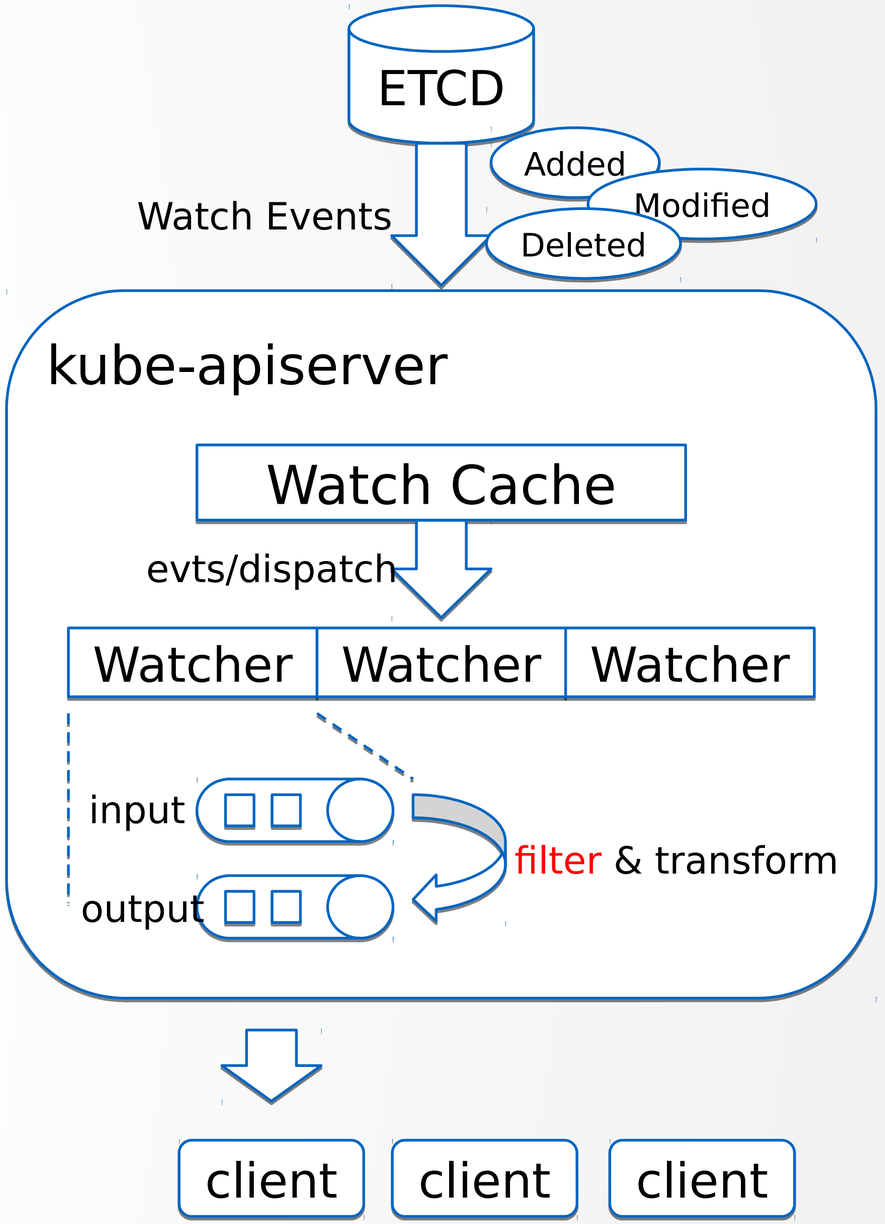

如何优化 Kubernetes？

pprof 例子 2

- 问题：每次过滤，从实例中取可过滤的 attr map(由每个实例的 GetAttr 生成)，包含可过滤的 key 和 实例对应的属性值， N 个实例就有 N 个临时 Map 生成
- 每种资源， attr map 结构一样， key 相同，只有 value 不一致

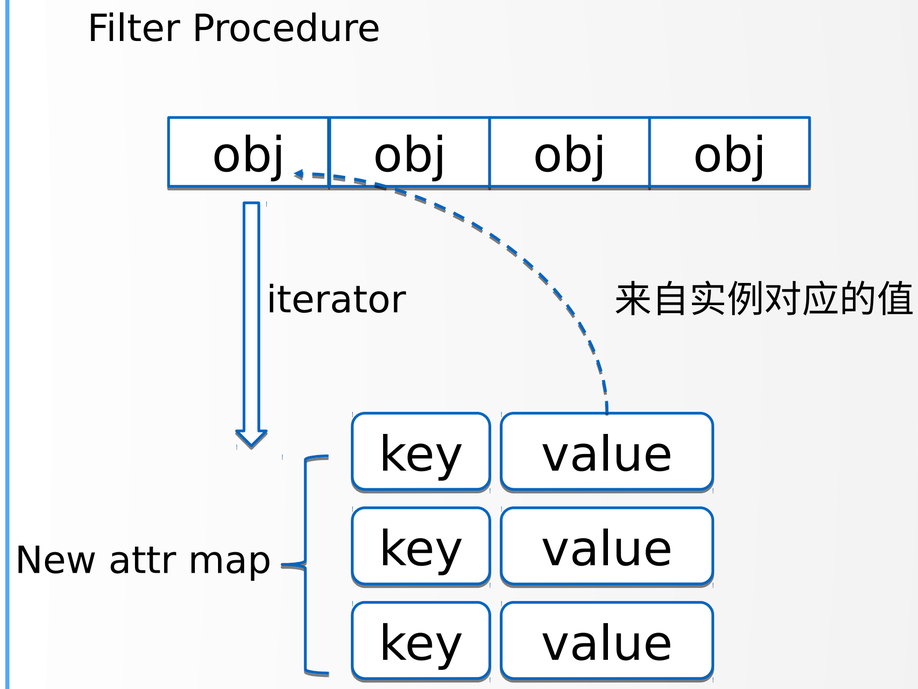


```
209 // PodToSelectableFields returns a field set that represents the object
210 // TODO: fields are not labels, and the validation rules for them do not apply.
211 func PodToSelectableFields(pod *api.Pod) fields.Set {
212     // The purpose of allocation with a given number of elements is to reduce
213     // amount of allocations needed to create the fields.Set. If you add any
214     // field here or the number of object-meta related fields changes, this sho ld
215     / be adjusted.
216     podSpecificFieldsSet := make(fields.Set, 5)
217     podSpecificFieldsSet["spec.nodeName"] = pod.Spec.NodeName
218     podSpecificFieldsSet["spec.restartPolicy"] = string(pod.Spec.RestartPolicy)
219     podSpecificFieldsSet["status.phase"] = string(pod.Status.Phase)
220     return generic.AddObjectMetaFieldsSet(podSpecificFieldsSet, &pod.ObjectMeta, tr
221 }
```

如何优化 Kubernetes？

pprof 例子 2

- 优化：既然每个 value 都来自实例，那么就可以直接通过方法返回
- 例如： pod 对应的 filter 所需的 map

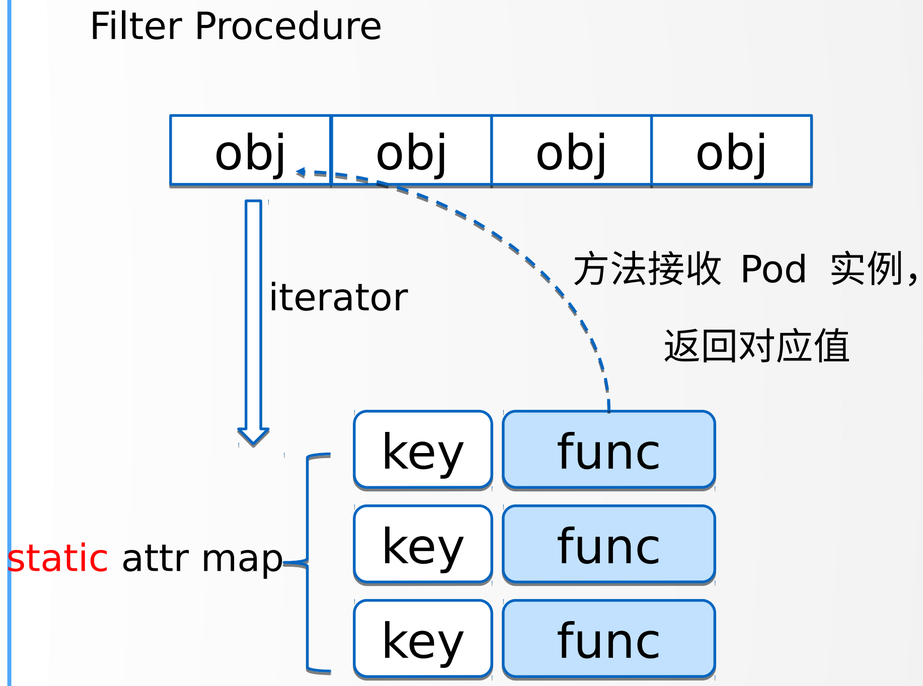


```
164 var podFieldCallbak = fields.CallbackSet{
165     "metadata.name":       func(obj runtime.Object) string { return obj.(*api.Pod).ObjectMeta.Name },
166     "metadata.namespace": func(obj runtime.Object) string { return obj.(*api.Pod).ObjectMeta.Namespace },
167
168     "spec.nodeName":       func(obj runtime.Object) string { return obj.(*api.Pod).Spec.NodeName },
169     "spec.restartPolicy": func(obj runtime.Object) string { return string(obj.(*api.Pod).Spec.RestartPolicy) },
170     "status.phase":        func(obj runtime.Object) string { return string(obj.(*api.Pod).Status.Phase) },
171 }
```

www.163yun.com

如何优化 Kubernetes？

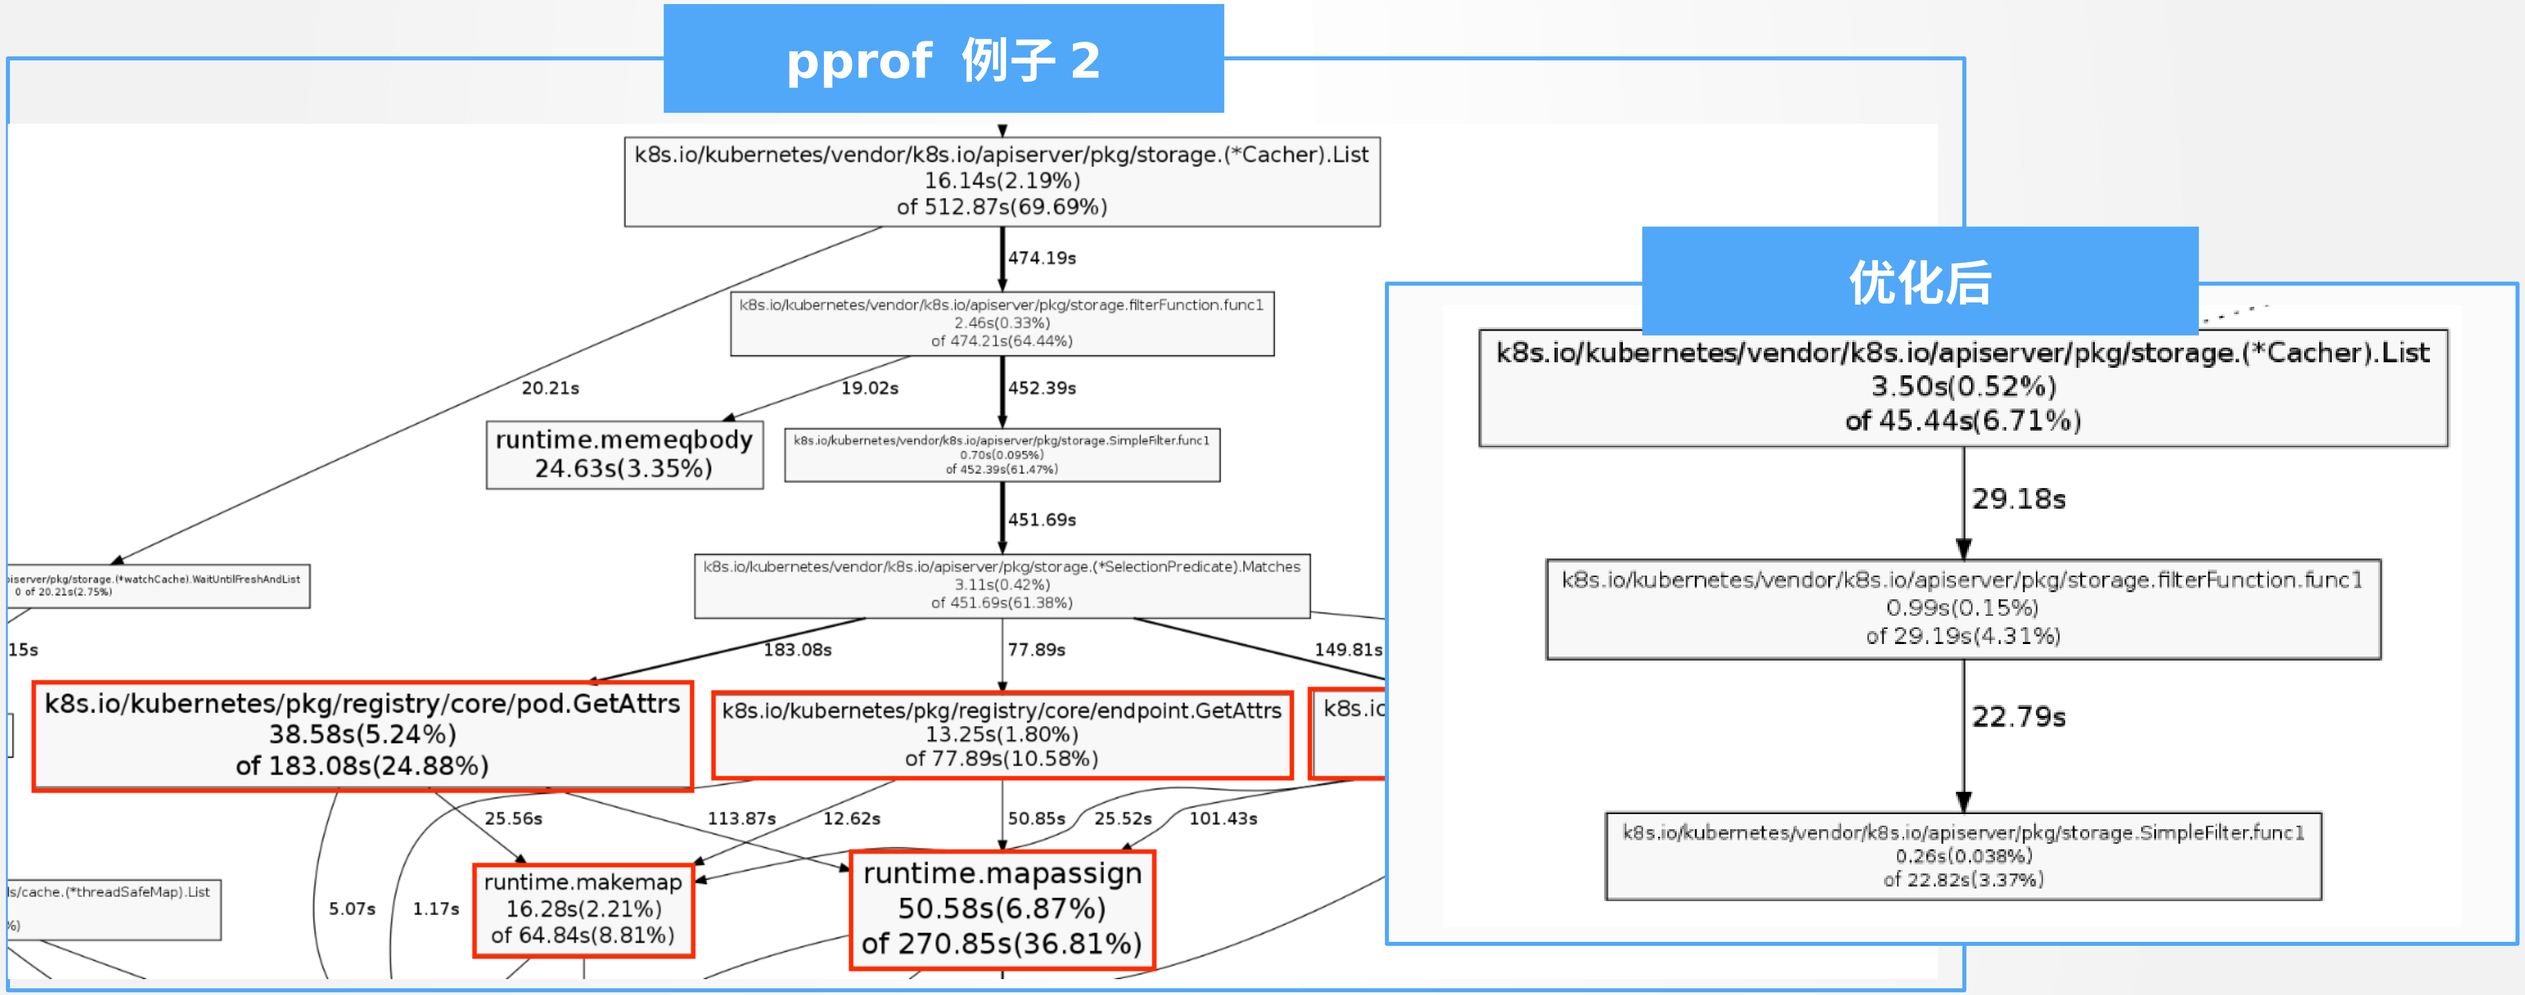

如何优化 Kubernetes？

网易云

其他优化

- APIServer 等待缓存层同步完成再服务
- Kubemark 同时模拟多个 Node，性能提升 10x，满足线下性能测试需求
- 网络方案采用 sriov，提高容器网络传输效率
- kubelet/kube-proxy CPU/ 内存 / 优化，例如 kubelet/proxy 只需关心少量资源存在（List&Watch 资源时增加过滤）
- ……

未来的优化

未来的优化

接下来的优化

- 继续提升水位，满足一个机房容量需求
- 优化 Node 心跳汇报 / 各类控制器
- Client 端优化
- 高性能容器、网络优化
- 回馈社区

想知道更多？

云原生应用架构实践

- 我司各种大牛之精华
- 集团 10+ 年实践总结
- 非常有操作性和指导性
- 详解了云原生应用的内涵和要点，对实现云原生应用面临的功能和非功能（高性能、高可用、可扩展、安全性、高可靠等）的不同阶段需求和实现方案
- 系统工程化、高性能数据库、分布式数据库、 DevOps 、微服务架构、服务化测试、多机房架构等
- 适合希望采用云计算帮助企业实现业务提升的 CTO 、 CIO 、架构师等群体


网易云
共创云上精彩世界
网易云
www.163yun.com